МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
имени М.В. Ломоносова
Факультет вычислительной математики и кибернетики

Учебный курс
«ТЕХНОЛОГИЧЕСКИЙ ПРАКТИКУМ»

Отчёт
о выполненном задании

студентки 316 учебной группы факультета ВМК МГУ
Морозова Софьи Васильевны

Москва
2025

Содержание

1 Описание датасета, краткие характеристики (максимумы, минимумы, средние значения, пропуски и т.п.) 6

2 Реализовать аппроксимацию распределений данных с помощью ядерных оценок. 9

2.1 Метод ядерной оценки плотности (KDE) . . . 9
2.2 Преимущества KDE . . . 9
2.3 Выводы . . . 10
2.4 Взаимосвязь дохода и кредитного рейтинга . . . 10

3 Анализ данных с помощью cdplot, dotchart, boxplot и stripchart 11

3.1 График условной плотности (cdplot) . . . 11
3.2 Анализ графика условной плотности Monthly_Inhand_Salary по Credit_Score 11
3.2.1 Выводы . . . 11
3.3 Точечная диаграмма (dotchart) . . . 12
3.4 Анализ по dotchart . . . 13
3.4.1 Распределение коэффициента использования кредита по кредитному рейтингу . . . 13
3.5 Диаграмма "ящик с усами"(boxplot) . . . 13
3.6 Анализ boxplot . . . 14
3.6.1 Распределение количества банковских счетов по кредитному рейтингу 14
3.6.2 Распределение годового дохода по кредитному рейтингу (логарифмическая шкала) . . . 14
3.6.3 Общие выводы . . . 15
3.7 3.4 Точечная диаграмма с разбросом (stripplot) . . . 15
3.8 Анализ точечной диаграммы с разбросом Annual_Income по профессиям . . 15
3.8.1 Визуализация распределения доходов . . . 15
3.8.2 Выводы по распределению доходов . . . 16

4 Проверить, являются ли наблюдения выбросами с точки зрения формальных статистических критериев Граббса и Q-теста Диксона. 16

4.1 Критерий Граббса . . . 16
4.1.1 Алгоритм применения критерия Граббса: . . . 16
4.2 Поиск и удаление выбросов в сгенерированной выборке . . . 16
4.3 Q-тест Диксона . . . 17
4.3.1 Алгоритм применения Q-теста Диксона: . . . 17
4.3.2 Критические значения Q-теста Диксона: . . . 18
4.4 Применение Q-теста Диксона к сгенерированной выборке . . . 18
4.4.1 Экспериментальная setup . . . 18
4.4.2 Результаты применения критерия . . . 18
4.4.3 Анализ результатов . . . 18

5 Заполнение пропусков в данных 19

5.1 Методы заполнения пропусков . . . 19
5.1.1 Заполнение средним значением . . . 19
5.1.2 Заполнение медианой . . . 19
5.2 Визуализация результатов заполнения пропусков . . . 20
5.3 Анализ результатов . . . 20
5.3.1 Выводы: . . . 21

6 Анализ нормального распределения на выборках различного объема 21
6.1 Анализ с помощью эмпирических функций распределения 21
6.1.1 Свойства эмпирической функции распределения: 21
6.1.2 Методика анализа: 22
6.2 Анализ эмпирических функций распределения 22
6.2.1 Наблюдения по малым выборкам: 22
6.2.2 Наблюдения по большим выборкам: 23
6.2.3 Выводы: 23
6.3 Анализ с помощью графиков квантилей (Q-Q plot) 23
6.3.1 Математическая основа метода 23
6.3.2 Интерпретация Q-Q графиков 24
6.4 Анализ графиков квантилей (Q-Q plots) 24
6.4.1 Анализ малых выборок: 24
6.4.2 Выводы: 25
6.5 Анализ с помощью метода огибающих (Envelope Method) 25
6.5.1 Преимущества метода 26
6.6 Анализ метода огибающих с 99% доверительными границами 26
6.6.1 Анализ малых выборок: 26
6.6.2 Анализ больших выборок: 27
6.6.3 Статистические выводы: 27
6.7 Стандартные процедуры проверки гипотез о нормальности 27
6.7.1 Критерий Колмогорова-Смирнова 27
6.8 Результаты применения критерия Колмогорова-Смирнова 28
6.8.1 Сравнительный анализ результатов на Python и R 28
6.8.2 Анализ результатов 28
6.8.3 Общие выводы 29
6.9 Критерий Шапиро-Уилка 29
6.9.1 Анализ результатов 30
6.9.2 Общие выводы 30
6.10 Критерий Андерсона-Дарлинга 30
6.10.1 Анализ результатов 31
6.10.2 Общие выводы 31
6.11 Критерий Крамера-фон Мизеса 31
6.11.1 Анализ результатов 32
6.11.2 Общие выводы 33
6.12 Критерий Колмогорова-Смирнова в модификации Лиллиефорса 33
6.12.1 Анализ результатов 34
6.12.2 Общие выводы 34
6.13 Критерий Шапиро-Франсия 34
6.13.1 Анализ результатов 35
6.13.2 Общие выводы 35
6.14 Итоговые выводы по анализу нормальности 36

7 Анализ нормальности на реальных данных с применением графических методов и статистических критериев 36
7.1 Описание данных и предобработка 36
7.2 Методика стандартизации 36
7.3 Графический анализ нормальности 37
7.3.1 Графики квантилей (Q-Q plots) 37
7.3.2 Метод огибающих 37

7.4 Статистические критерии нормальности . . . 38
7.5 Анализ результатов . . . 38
7.5.1 Наблюдения по графикам: . . . 38
7.5.2 Статистические выводы: . . . 38
7.6 Общие выводы . . . 39
7.7 Стандартные процедуры проверки гипотез о нормальности . . . 39
7.7.1 Результаты тестирования в Python . . . 39
7.7.2 Результаты тестирования в R . . . 39
7.7.3 Сравнительный анализ результатов . . . 40
7.8 Проверка нормальности критерием Шапиро-Уилка . . . 40
7.8.1 Результаты тестирования в Python . . . 40
7.8.2 Результаты тестирования в R . . . 40
7.8.3 Анализ дополнительных проверок . . . 41
7.9 Проверка нормальности критерием Андерсона-Дарлинга . . . 41
7.9.1 Результаты тестирования в Python . . . 41
7.9.2 Результаты тестирования в R . . . 41
7.9.3 Анализ результатов критерия Андерсона-Дарлинга . . . 42
7.10 Проверка нормальности критерием Крамера-фон Мизеса . . . 42
7.10.1 Результаты тестирования в Python . . . 42
7.10.2 Результаты тестирования в R . . . 42
7.10.3 Анализ результатов критерия Крамера-фон Мизеса . . . 43
7.11 Проверка нормальности критерием Лиллиефорса . . . 43
7.11.1 Результаты тестирования в Python . . . 43
7.11.2 Результаты тестирования в R . . . 43
7.11.3 Анализ результатов критерия Лиллиефорса . . . 44
7.12 Проверка нормальности критерием Шапиро-Франсиа . . . 44
7.12.1 Результаты тестирования в Python . . . 44
7.12.2 Результаты тестирования в R . . . 44
7.12.3 Анализ результатов критерия Шапиро-Франсиа . . . 45

8 Применение критериев Стьюдента для различных гипотез и доверительных уровней 45
8.1 Двусторонний критерий Стьюдента . . . 45
8.2 Односторонний критерий Стьюдента (Greater) . . . 45
8.3 Односторонний критерий Стьюдента (Less) . . . 46
8.4 Общие выводы по критериям Стьюдента . . . 46
8.5 Определение объема выборки для достижения заданной мощности . . . 47
8.6 Двухвыборочный критерий Стьюдента для рейтингов белых и черных . . . 47
8.6.1 Двусторонний критерий Стьюдента . . . 48
8.6.2 Односторонний критерий Стьюдента (Greater) . . . 48
8.6.3 Односторонний критерий Стьюдента (Less) . . . 49
8.6.4 Общие выводы по двухвыборочному критерию . . . 49
8.7 Ранговый критерий Уилкоксона-Манна-Уитни . . . 49
8.8 Проверка гипотез об однородности дисперсий . . . 50
8.8.1 Критерий Фишера, критерий Левене, критерий Бартлетта, критерий Флигнера-Килина . . . 51

9 Исследование корреляционных взаимосвязей в данных **52**
9.1 Коэффициент корреляции Пирсона 52
9.2 Коэффициент корреляции Спирмена 52
9.3 Коэффициент корреляции Кендалла 53
9.4 Сравнительные выводы 53

10 Анализ категориальных данных с использованием методов хи-квадрат, точного теста Фишера, теста МакНемара и Кохрана-Мантеля-Хензеля **54**
10.1 Критерий хи-квадрат Пирсона 54
10.2 Точный тест Фишера 54
10.3 Тест МакНемара 55
10.4 Тест Кохрана-Мантеля-Хензеля (CMH) 55
10.5 Сравнительный анализ методов 56

11 Анализ мультиколлинеарности в данных **57**
11.1 Анализ корреляционной матрицы 57
11.2 Фактор инфляции дисперсии (VIF) 58
11.3 Выводы 59

12 Исследование зависимостей в данных с помощью дисперсионного анализа **59**
12.1 Метод дисперсионного анализа (ANOVA) 59
12.2 Однофакторный дисперсионный анализ кредитных данных 59
12.3 Однофакторный дисперсионный анализ шахматных данных 60
12.4 Общие выводы 60

13 Регрессионное моделирование и оценка качества аппроксимации **61**
13.1 Анализ регрессионных моделей для датасета фильмов 61
13.1.1 Простая линейная регрессия: популярность от количества оценок . . 61
13.1.2 Полиномиальная регрессия: средняя оценка от популярности 62
13.2 Анализ регрессионных моделей для шахматного датасета 62
13.2.1 Простая линейная регрессия: количество ходов от рейтинга белых . . 62
13.2.2 Полиномиальная регрессия: количество ходов от рейтинга белых . . . 63
13.2.3 Множественная линейная регрессия для шахматных данных 63
13.3 Комплексная полиномиальная регрессия всех числовых переменных 63
13.4 Общие выводы и интерпретация 64

1 Описание датасета, краткие характеристики (максимумы, минимумы, средние значения, пропуски и т.п.)

Датасет представляет собой набор финансовых критериев, касающихся кредитов. Кредитный рейтинг может быть одним из трех типов: хороший, стандартный, плохой. Ниже приведено краткое описание ключевых столбцов:

1. Occupation — Род занятий потребителя
2. Annual_Income — Годовой доход
3. Monthly_Inhand_Salary — Ежемесячная зарплата
4. Num_Bank_Accounts — Количество банковских счетов
5. Num_Credit_Card — Количество кредитных карт
6. Interest_Rate — Процентная ставка
7. Num_of_Loan — Количество кредитов
8. Delay_from_due_date — Отложенный срок выполнения
9. Num_of_Delayed_Payment — Количество просроченных платежей
10. Changed_Credit_Limit — Изменен кредитный лимит
11. Num_Credit_Inquiries — Количество запросов по кредитам
12. Credit_Mix — Структура кредитов
13. Outstanding_Debt — Непогашенная задолженность
14. Credit_Utilization_Ratio — Коэффициент использования кредита
15. Credit_History_Age — Возраст кредитной истории
16. Payment_of_Min_Amount — Минимальная сумма платежа
17. Total_EMI_per_month — Общий объем инвестиций в месяц
18. Amount_invested_monthly — Сумма ежемесячных инвестиций
19. Payment_Behaviour — Порядок осуществления платежей
20. Monthly_Balance — Баланс за месяц
21. Customer_ID — Айдишник потребителя
22. Age — Возраст потребителя
23. Credit_Score — Целевая переменная (Poor — плохой, Standard — стандартный, Good — хороший).

Статистика	Age	Annual_Income	Monthly_Inhand_Salary
count	100000.00	100000.00	100000.00
mean	33.31	50505.12	4198.77
std	10.76	38299.42	3187.49
min	14.00	7005.93	303.65
25%	24.00	19342.97	1626.76
50%	33.00	36999.71	3096.38
75%	42.00	71683.47	5961.75
max	56.00	179987.28	15204.63

Таблица 1: Демографические показатели и доходы

Статистика	Num_Bank_Accounts	Num_Credit_Card	Num_of_Loan
count	100000.00	100000.00	100000.00
mean	5.37	5.53	3.53
std	2.59	2.07	2.45
min	0.00	0.00	0.00
25%	3.00	4.00	2.00
50%	5.00	5.00	3.00
75%	7.00	7.00	5.00
max	11.00	11.00	9.00

Таблица 2: Количество финансовых продуктов

Статистика	Interest_Rate	Delay_from_due_date	Num_of_Delayed_Payment
count	100000.00	100000.00	100000.00
mean	14.53	21.07	13.33
std	8.74	14.86	6.27
min	1.00	-5.00	0.00
25%	7.00	10.00	9.00
50%	13.00	18.00	14.00
75%	20.00	28.00	18.00
max	34.00	67.00	28.00

Таблица 3: Кредитные условия и платежная дисциплина

Статистика	Changed_Credit_Limit	Num_Credit_Inquiries	Outstanding_Debt
count	100000.00	100000.00	100000.00
mean	10.39	5.77	1426.22
std	6.78	3.86	1155.13
min	-6.49	0.00	0.23
25%	5.34	3.00	566.07
50%	9.40	5.00	1166.16
75%	14.85	8.00	1945.96
max	36.97	17.00	4998.07

Таблица 4: Кредитные лимиты и долговая нагрузка

Статистика	Credit_Utilization_Ratio	Credit_History_Age	Monthly_Balance
count	100000.00	100000.00	100000.00
mean	32.29	221.21	403.49
std	5.12	99.68	214.42
min	20.00	1.00	0.01
25%	28.05	144.00	270.32
50%	32.31	219.00	337.27
75%	36.50	302.00	471.93
max	50.00	404.00	1602.04

Таблица 5: Кредитное поведение и финансовые показатели

Анализ датасета на основе статистических характеристик

- Пропусков в датасете нет, что подтверждается проверкой методом df.isnull().any().
- Средний возраст клиентов составляет около 33 лет, при этом диапазон возрастов от 14 до 56 лет охватывает различные этапы финансовой активности.
- Годовой доход имеет очень широкий разброс — от 7 005 до 179 987 долларов, что отражает значительное экономическое разнообразие среди клиентов.
- Количество банковских счетов и кредитных карт распределено относительно равномерно, со средними значениями 5.37 и 5.53 соответственно, однако максимальные значения (11) указывают на наличие клиентов с чрезмерным количеством финансовых продуктов.
- Процентные ставки по кредитам варьируются от 1% до 34%, демонстрируя широкий спектр кредитных условий, доступных клиентам.
- Показатели платежной дисциплины выявляют серьезные проблемы: максимальная просрочка по платежам достигает 67 дней, а количество просроченных платежей — до 28 раз, что свидетельствует о наличии клиентов с критически низкой финансовой дисциплиной.
- Непогашенная задолженность показывает экстремальные значения — от 0.23 до 4 998.07 долларов, указывая на наличие клиентов с очень высокой долговой нагрузкой.
- Коэффициент использования кредита находится в разумных пределах (20-50%), что соответствует стандартным банковским практикам.
- Возраст кредитной истории варьируется от 1 до 404 месяцев, охватывая как новых, так и опытных заемщиков.
- Ежемесячный баланс клиентов показывает значительный разброс — от почти нулевого значения (0.00776) до 1 602.04 долларов, отражая разнообразие финансовых возможностей клиентов.

Общий анализ показывает, что датасет содержит разнородную выборку клиентов с различными финансовыми профилями.

2 Реализовать аппроксимацию распределений данных с помощью ядерных оценок.

2.1 Метод ядерной оценки плотности (KDE)

Ядерная оценка плотности (Kernel Density Estimation, KDE) — это метод аппроксимации функции плотности вероятности случайной величины с использованием конечной выборки. Он не предполагает конкретного распределения данных, а оценивает форму распределения непосредственно по точкам данных. Также KDE сглаживает гистограмму, которая показывает, как распределены данные.

Математически KDE определяется как:

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - x_i}{h}\right)$$

где:

- K — ядерная функция (обычно гауссова)
- h — параметр сглаживания (bandwidth)
- n — количество наблюдений
- x_i — точки данных

2.2 Преимущества KDE

- Не требует предположений о форме распределения
- Обеспечивает гладкую оценку плотности

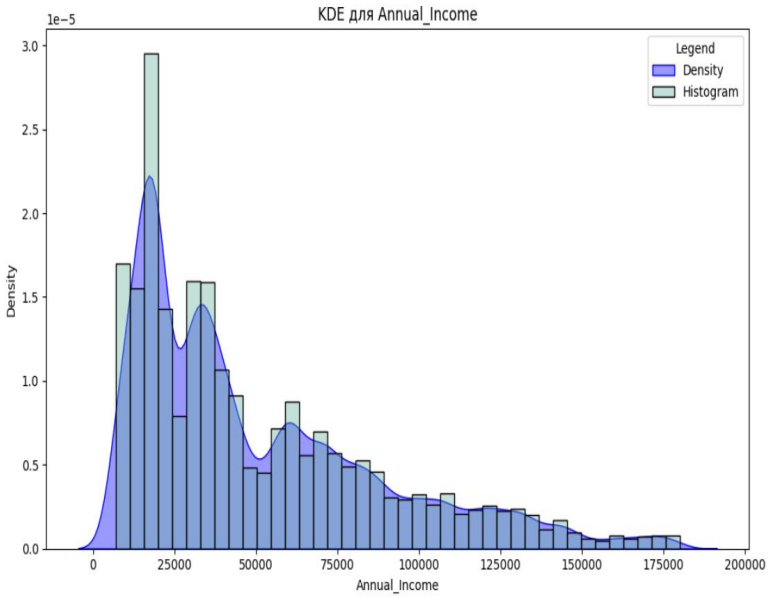

Рис. 1: График распределения данных

2.3 Выводы

- Логнормальное распределение совпадает с хвостом распределения для `Annual_Income`.
- Выраженные выбросы отсутствуют.
- Метод сглаживания корректен, так как плотность, отображаемая KDE, согласуется с гистограммой.

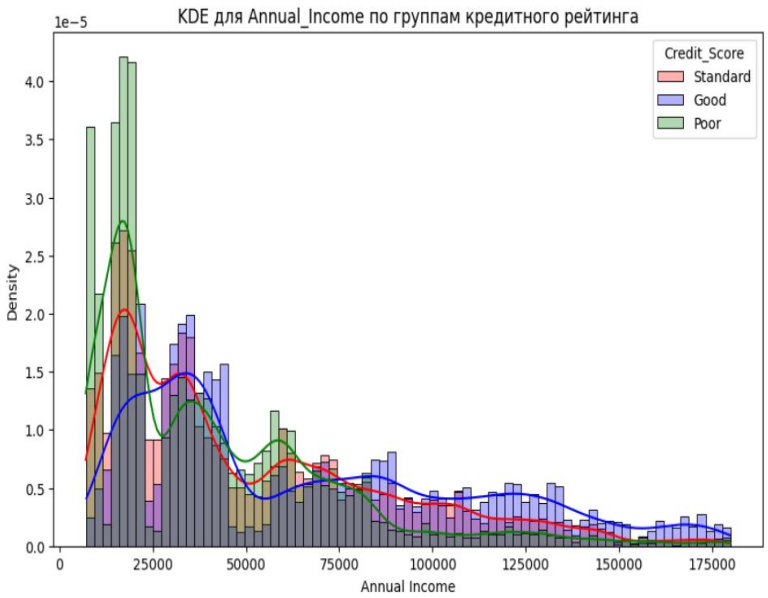

Рис. 2: График распределения данных

2.4 Взаимосвязь дохода и кредитного рейтинга

Анализ ядерных оценок плотности распределения годового дохода по группам кредитного рейтинга показывает:

- Каждая кривая KDE соответствует определённой категории кредитного рейтинга (`Credit_Score`)
- Обнаружена положительная корреляция между уровнем дохода и кредитным рейтингом
- Клиенты с более высоким годовым доходом статистически чаще имеют благоприятный кредитный рейтинг
- Моды распределений смещаются вправо по мере улучшения кредитного рейтинга

Это подтверждает ожидаемую финансовую закономерность: доход является значимым фактором при оценке кредитоспособности.

3 Анализ данных с помощью cdplot, dotchart, boxplot и stripchart

3.1 График условной плотности (cdplot)

График условной плотности (Conditional Density Plot, cdplot) — это метод визуализации, который отображает распределение непрерывной переменной в разрезе категориальных групп. Данный тип графика позволяет анализировать, как меняется плотность распределения количественного признака при переходе между различными категориями факторной переменной.

Основная цель cdplot — наглядно продемонстрировать различия в распределениях непрерывной переменной для отдельных подгрупп, определяемых категориальным признаком.

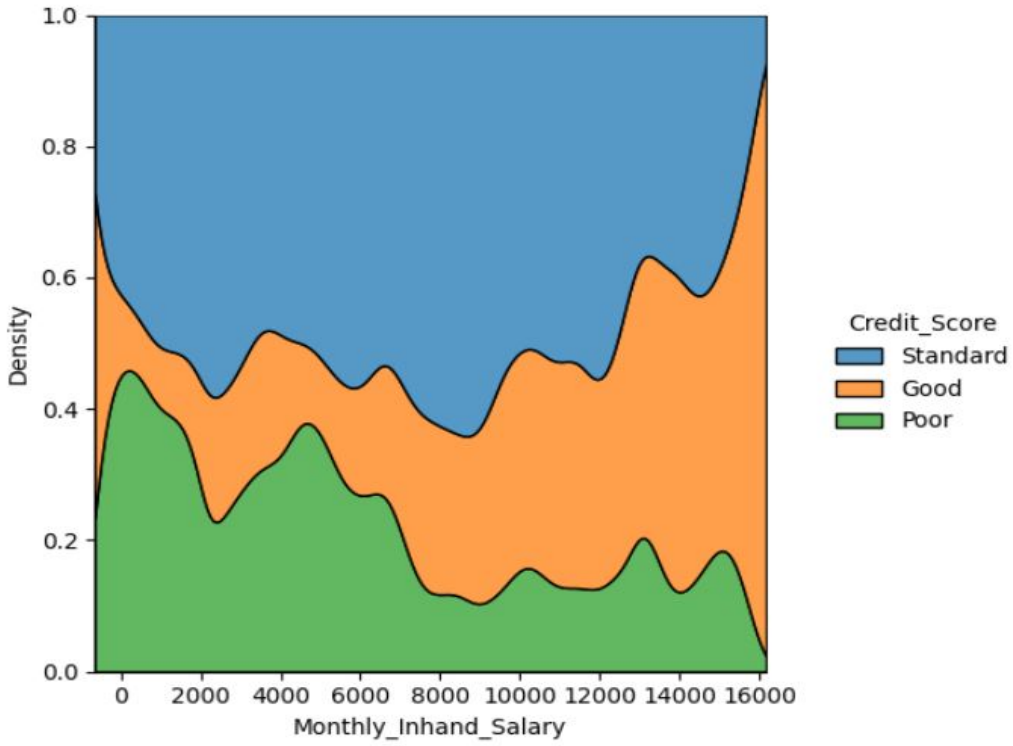

Рис. 3: cdplot

3.2 Анализ графика условной плотности Monthly_Inhand_Salary по Credit_Score

На графике представлено распределение ежемесячной зарплаты (`Monthly_Inhand_Salary`) в зависимости от кредитного рейтинга (`Credit_Score`). По оси X отложена величина месячного дохода, по оси Y — условная вероятность принадлежности к определенному кредитному рейтингу.

3.2.1 Выводы

- Клиенты с низким доходом (до 4000) преимущественно имеют кредитный рейтинг `Poor`
- При средних доходах (4000–8000) доминирует рейтинг `Standard`

- Клиенты с высоким доходом (свыше 8000) в основном относятся к категории `Good`
- Наблюдается четкое разделение кредитных рейтингов по уровню дохода
- Существует сильная зависимость между уровнем ежемесячного дохода и кредитным рейтингом

3.3 Точечная диаграмма (dotchart)

Точечная диаграмма (dotchart) отображает значения количественного признака по категориям в виде отдельных точек. Данный тип визуализации позволяет эффективно сравнивать распределения непрерывных переменных между различными группами, определяемыми категориальным признаком.

Для анализа были выбраны переменные `Num_of_Loan` (количество кредитов) и `Credit_Utilizatio` (коэффициент использования кредита). Графики позволяют оценить, как распределяются эти финансовые показатели между категориями кредитного рейтинга.

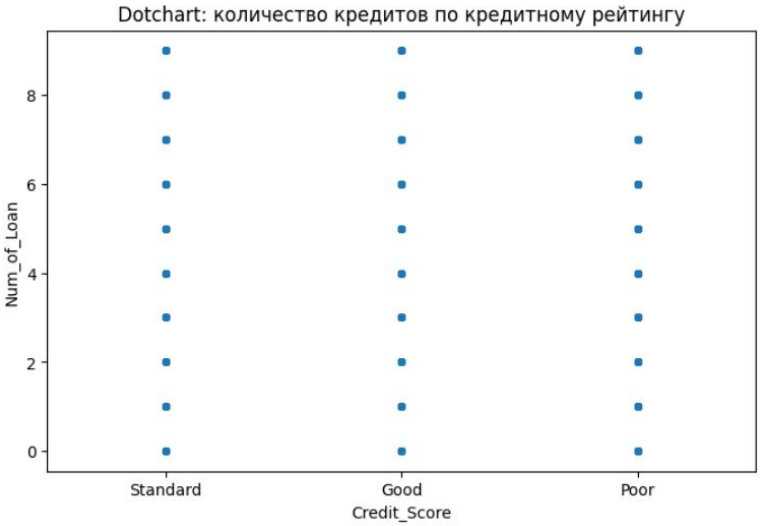

Рис. 4: Распределение количества кредитов по кредитному рейтингу

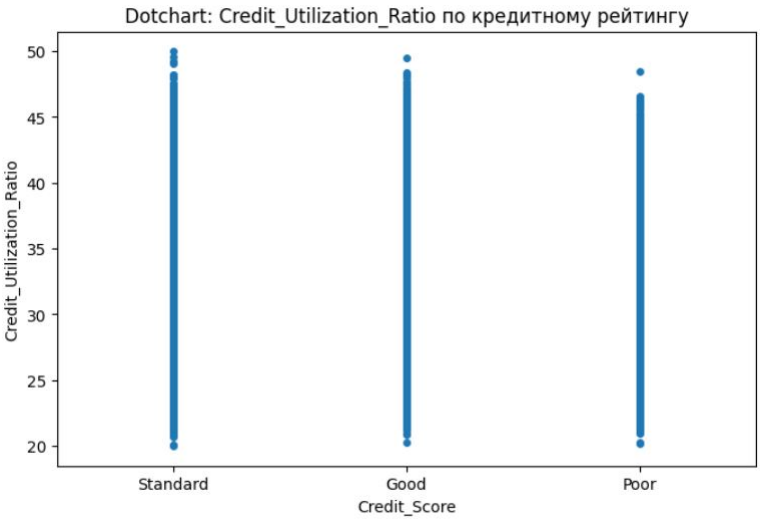

Рис. 5: Распределение коэффициента использования кредита по кредитному рейтингу

3.4 Анализ по dotchart

3.4.1 Распределение коэффициента использования кредита по кредитному рейтингу

Анализ для Credit_Utilization_Ratio:

- Клиенты категории **Good** имеют наиболее низкие значения коэффициента использования кредита, что характеризует их как финансово стабильных заемщиков
- Группа **Standard** показывает умеренные значения коэффициента
- Заемщики с рейтингом **Poor** демонстрируют наиболее высокие значения коэффициента, что свидетельствует о высокой кредитной нагрузке

3.5 Диаграмма "ящик с усами"(boxplot)

Диаграмма "ящик с усами"(boxplot) — это инструмент визуализации, который позволяет анализировать распределение количественных данных по различным категориям. Данный тип графика предоставляет следующую информацию:

- Показывает, где сосредоточена основная масса данных
- Отражает степень разброса значений внутри категорий
- Позволяет выявить выбросы — значения, выходящие за пределы "усов"
- Визуализирует медиану, квартили и межквартильный размах

Для анализа были построены диаграммы "ящик с усами"по ключевым финансовым показателям, сгруппированным по кредитному рейтингу. Это позволяет оценить различия в распределениях между категориями `Good`, `Standard` и `Poor`.

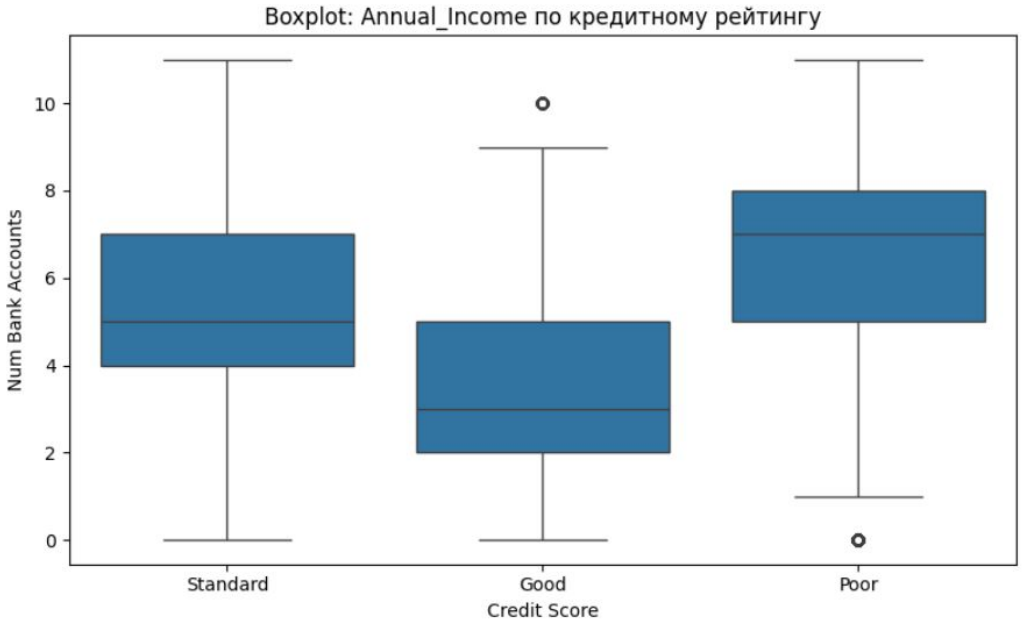

Рис. 6: Распределение годового дохода по кредитному рейтингу

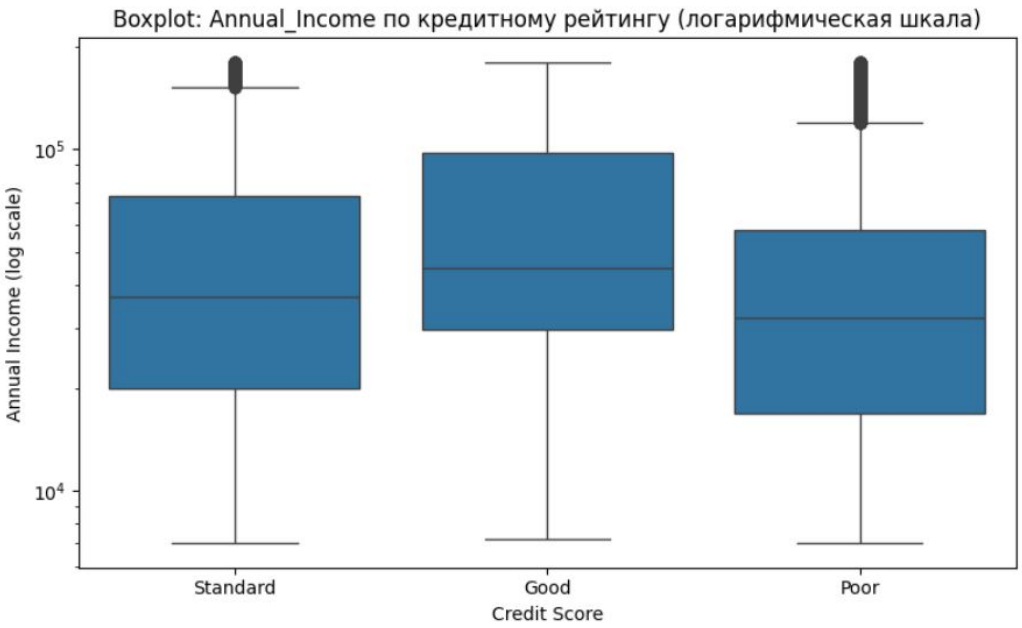

Рис. 7: Распределение непогашенной задолженности по кредитному рейтингу

3.6 Анализ boxplot

3.6.1 Распределение количества банковских счетов по кредитному рейтингу

Анализ boxplot для переменной `Num_Bank_Accounts`:

- Медианное значение количества счетов примерно одинаково для всех категорий кредитного рейтинга
- Группа Poor демонстрирует наибольший разброс значений и наличие выбросов
- Клиенты с рейтингом Good имеют наиболее компактное распределение, что свидетельствует о однородности данной группы
- Межквартильный размах у категории Standard занимает промежуточное положение

3.6.2 Распределение годового дохода по кредитному рейтингу (логарифмическая шкала)

Анализ boxplot для годового дохода:

- Группа Good имеет наибольший медианный доход, затем следует Standard, и наименьший доход у категории Poor
- Распределение доходов в группе Poor имеет наибольший разброс, включая значительные выбросы
- Логарифмирование позволило нормализовать распределение и лучше визуализировать различия между группами

3.6.3 Общие выводы

1. Годовой доход является более значимым предиктором кредитного рейтинга, чем количество банковских счетов

2. Клиенты с высоким кредитным рейтингом Good характеризуются не только высокими доходами, но и большей финансовой стабильностью

3. Группа Poor демонстрирует наибольшую неоднородность как по доходам, так и по количеству банковских счетов

3.7 3.4 Точечная диаграмма с разбросом (stripplot)

Точечная диаграмма с разбросом (stripplot) является модификацией обычного dotchart, которая добавляет случайное смещение точек вдоль категориальной оси за счет параметра `jitter=True`. Этот прием предотвращает наложение точек друг на друга и позволяет более наглядно оценить плотность распределения данных в каждой категории.

Для анализа были выбраны топ-5 наиболее распространенных профессий в датасете. Исследование плотности распределения точек для этих профессиональных групп позволяет выявить особенности финансового поведения в разрезе профессиональной деятельности.

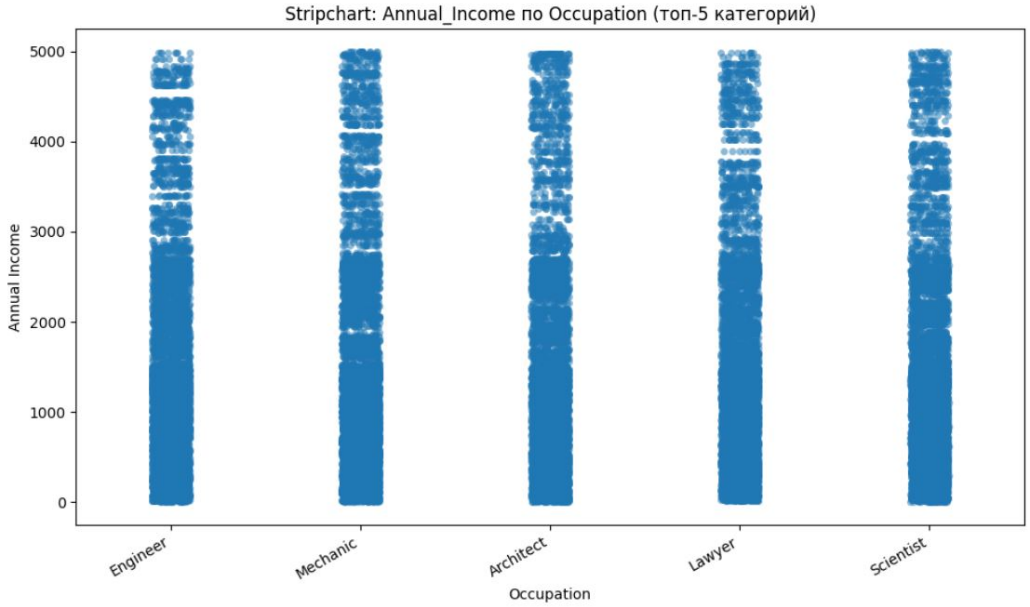

Рис. 8: Распределение годового дохода для топ-5 профессий

3.8 Анализ точечной диаграммы с разбросом Annual_Income по профессиям

3.8.1 Визуализация распределения доходов

На графике представлено распределение годового дохода для топ-5 наиболее распространенных профессий в датасете. Использование параметра `jitter=True` позволяет наглядно оценить плотность распределения точек для каждой профессиональной группы.

3.8.2 Выводы по распределению доходов

- Профессия Engineer демонстрирует наибольший разброс доходов с концентрацией в среднем и высоком диапазоне
- Lawyer и Scientist показывают сравнительно высокие медианные значения доходов
- Профессия Mechanic имеет наиболее компактное распределение с преобладанием средних значений дохода
- Architect занимает промежуточное положение по уровню доходов среди представленных профессий
- Во всех профессиональных группах наблюдается значительный разброс значений, что свидетельствует о неоднородности доходов внутри каждой профессии

4 Проверить, являются ли наблюдения выбросами с точки зрения формальных статистических критериев Граббса и Q-теста Диксона.

4.1 Критерий Граббса

Критерий Граббса применяется для выявления выбросов в выборках, имеющих приблизительно нормальное распределение. Основная идея метода заключается в определении значения, которое максимально удалено от среднего значения выборки, и оценке степени этого отклонения относительно стандартного отклонения.

4.1.1 Алгоритм применения критерия Граббса:

1. Вычислить среднее значение $\bar{x}$ и стандартное отклонение s для выборки
2. Найти значение x_i, наиболее удаленное от среднего:

$$G = \frac{\max |x_i - \bar{x}|}{s}$$

3. Сравнить полученную статистику G с критическим значением $G_{\text{крит}}$ для выбранного уровня значимости $\alpha = 0.05$
4. Если $G > G_{\text{крит}}$, то соответствующее значение считается выбросом

Уровень значимости принят равным 0.05.

4.2 Поиск и удаление выбросов в сгенерированной выборке

В ходе анализа было обнаружено, что при нормализации и стандартизации исходных данных статистические критерии не выявляют выбросы, несмотря на их визуальное наличие. Для проверки корректности работы алгоритмов и валидации методики было принято решение работать со сгенерированной выборкой.

1. Сгенерирована искусственная выборка с известными параметрами распределения
2. В данные добавлены выбросы
3. Проведена визуализация результатов для наглядного подтверждения эффективности метода

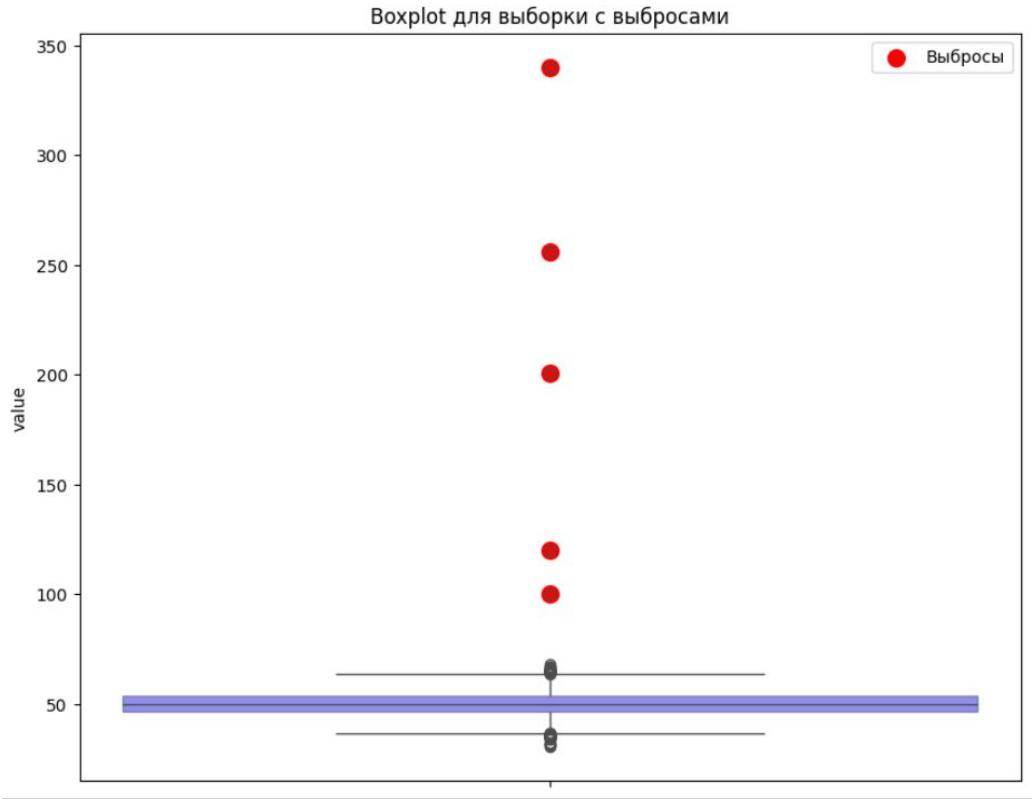

Рис. 9: Результаты обнаружения выбросов в сгенерированной выборке

4.3 Q-тест Диксона

Q-тест Диксона применяется для выявления выбросов в выборках малого объема — от 3 до 30 наблюдений. Метод проверяет одно значение, которое находится на значительном удалении от остальных наблюдений относительно общего разброса данных.

4.3.1 Алгоритм применения Q-теста Диксона:

1. Упорядочить выборку по возрастанию: $x_{(1)} \leq x_{(2)} \leq \ldots \leq x_{(n)}$
2. Вычислить размах выборки: $R = x_{(n)} - x_{(1)}$
3. Рассчитать Q-статистики для потенциальных выбросов:

   Для проверки минимального значения:

$$Q_{\min} = \frac{x_{(2)} - x_{(1)}}{R}$$

   Для проверки максимального значения:

$$Q_{\max} = \frac{x_{(n)} - x_{(n-1)}}{R}$$

4. Сравнить полученные статистики с критическим значением $Q_{\text{крит}}$ для уровня значимости $\alpha = 0.05$

5. Если $Q > Q_{\text{крит}}$, то соответствующее значение считается выбросом

4.3.2 Критические значения Q-теста Диксона:

Для уровня значимости $\alpha = 0.05$ критические значения составляют:

- $n = 3$: $Q_{\text{крит}} = 0.970$
- $n = 5$: $Q_{\text{крит}} = 0.710$
- $n = 10$: $Q_{\text{крит}} = 0.477$
- $n = 20$: $Q_{\text{крит}} = 0.342$
- $n = 30$: $Q_{\text{крит}} = 0.289$

Q-тест Диксона был применен к сгенерированным выборкам малого объема для проверки эффективности обнаружения выбросов.

4.4 Применение Q-теста Диксона к сгенерированной выборке

4.4.1 Экспериментальная setup

Для демонстрации работы Q-теста Диксона была сгенерирована выборка из нормального распределения объемом 25 наблюдений. В данные был искусственно добавлен один выброс — значение 360, значительно превышающее основную массу наблюдений.

4.4.2 Результаты применения критерия

Результаты статистического тестирования представлены ниже:

```
{
    'min_outlier': False,
    'max_outlier': True,
    'Q_min': 0.0204,
    'Q_max': 0.9320,
    'Qcrit': 0.273
}
```

4.4.3 Анализ результатов

- **Максимальное значение**: Q-статистика составила 0.9320, что значительно превышает критическое значение 0.273. Это подтверждает, что значение 360 является статистически значимым выбросом.

- **Минимальное значение**: Q-статистика равна 0.0204, что существенно ниже критического порога. Следовательно, минимальное значение выборки не классифицируется как выброс.

- **Заключение**: Критерий корректно идентифицировал искусственно добавленный выброс, подтвердив свою эффективность для обнаружения аномальных значений в малых выборках.

5 Заполнение пропусков в данных

В данном разделе рассматриваются методы восстановления пропущенных значений в данных. Пропуски были добавлены искусственно в случайные позиции, что позволяет точно оценить качество восстановления путем сравнения с исходными значениями.

5.1 Методы заполнения пропусков

5.1.1 Заполнение средним значением

При использовании данного метода каждое пропущенное значение заменяется на среднее арифметическое всех имеющихся значений в столбце.

Основные характеристики метода:

- Прост в реализации и интерпретации
- Сохраняет общее среднее значение выборки
- Может искажать данные при наличии выбросов
- Уменьшает естественную вариативность данных

5.1.2 Заполнение медианой

В этом подходе пропуски заполняются медианным значением столбца — таким значением, которое делит упорядоченную выборку пополам.

Особенности метода:

- Устойчив к экстремальным значениям и выбросам
- Лучше сохраняет исходное распределение асимметричных данных
- Может не учитывать важные закономерности в данных
- Особенно эффективен для данных с скошенным распределением

Среднее значение составило 3.53288, а медиана — 3.0. После добавления пропусков, медиана осталась 3.0, а среднее — 3.52088. В такой ситуации оба метода должны демонстрировать схожие результаты восстановления пропущенных значений.

5.2 Визуализация результатов заполнения пропусков

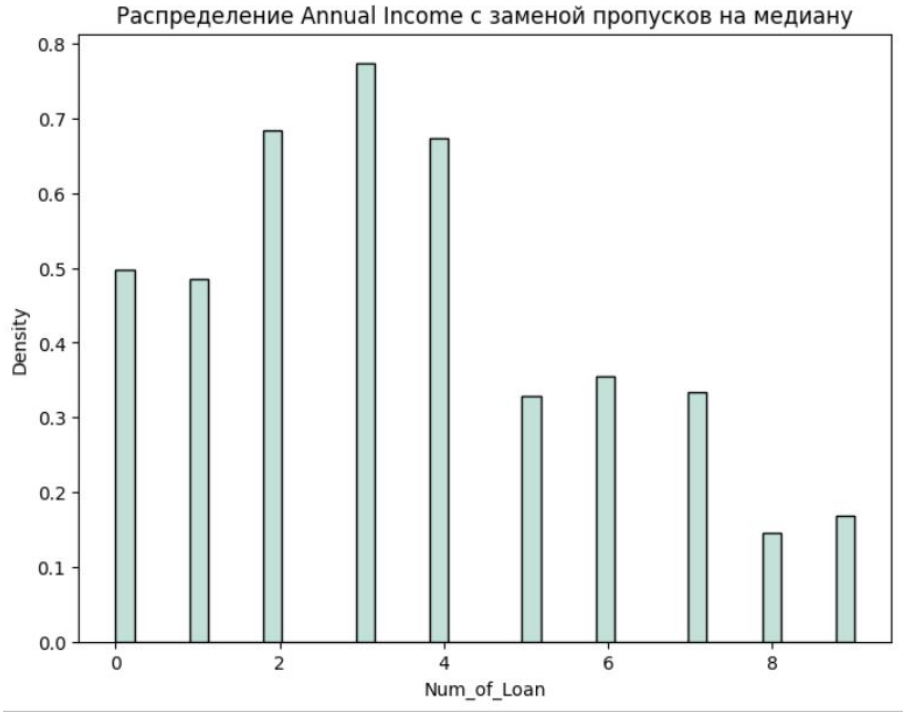

Рис. 10: Распределение Annual Income с заменой пропусков на медиану

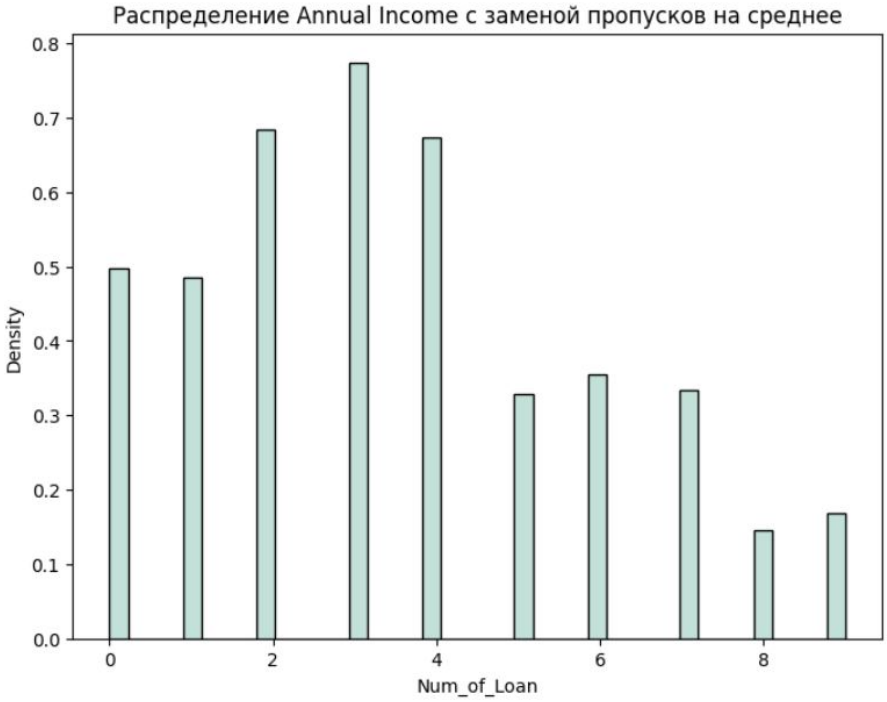

Рис. 11: Распределение Annual Income с заменой пропусков на среднее

5.3 Анализ результатов

На представленных графиках визуализируются распределения годового дохода после применения различных методов заполнения пропущенных значений.

5.3.1 Выводы:

- Оба метода демонстрируют схожую форму распределения, что согласуется с близкими значениями среднего и медианы
- Распределение сохраняет свои основные характеристики
- Плотность распределения в области средних значений остается практически неизменной
- Хвосты распределения также сохраняют свою структуру
- Заполнение медианой может быть предпочтительнее при наличии выбросов в данных
- Распределение не подвергается значительным искажениям при использовании любого из методов

6 Анализ нормального распределения на выборках различного объема

Для исследования свойств нормального распределения были сгенерированы четыре выборки с различными параметрами и объемами:

- **Выборка 1**: $n = 50$, $\mu = 0$, $\sigma = 1$ (малая выборка со стандартными параметрами)
- **Выборка 2**: $n = 100$, $\mu = 2$, $\sigma = 2$ (небольшая выборка со смещенным центром)
- **Выборка 3**: $n = 5000$, $\mu = 1$, $\sigma = 4$ (большая выборка с повышенной дисперсией)
- **Выборка 4**: $n = 2000$, $\mu = 11$, $\sigma = 3$ (крупная выборка со значительным смещением)

Такой набор выборок позволяет комплексно изучить влияние объема данных и параметров распределения на визуализацию и статистический анализ нормального распределения.

6.1 Анализ с помощью эмпирических функций распределения

Эмпирическая функция распределения (ЭФР) — это статистический инструмент, который позволяет оценить теоретическую функцию распределения на основе выборочных данных. Для выборки $x_1, x_2, \ldots, x_n$ эмпирическая функция распределения определяется как:

$$F_n(x) = \frac{\text{количество элементов выборки} \leq x}{n} = \frac{1}{n}\sum_{i=1}^{n} I_{\{x_i \leq x\}}$$

где $I_{\{x_i \leq x\}}$ — индикаторная функция, принимающая значение 1, если $x_i \leq x$, и 0 в противном случае.

6.1.1 Свойства эмпирической функции распределения:

- Является ступенчатой функцией с разрывами в точках наблюдений
- Неубывающая функция на всей числовой прямой
- $F_n(x) \to 0$ при $x \to -\infty$ и $F_n(x) \to 1$ при $x \to +\infty$
- Равномерно сходится к теоретической функции распределения при $n \to \infty$

6.1.2 Методика анализа:

Для каждой из сгенерированных выборок строится эмпирическая функция распределения и сравнивается с соответствующей теоретической нормальной функцией распределения $F(x) = \Phi\left(\frac{x-\mu}{\sigma}\right)$, где Φ — функция стандартного нормального распределения.

6.2 Анализ эмпирических функций распределения

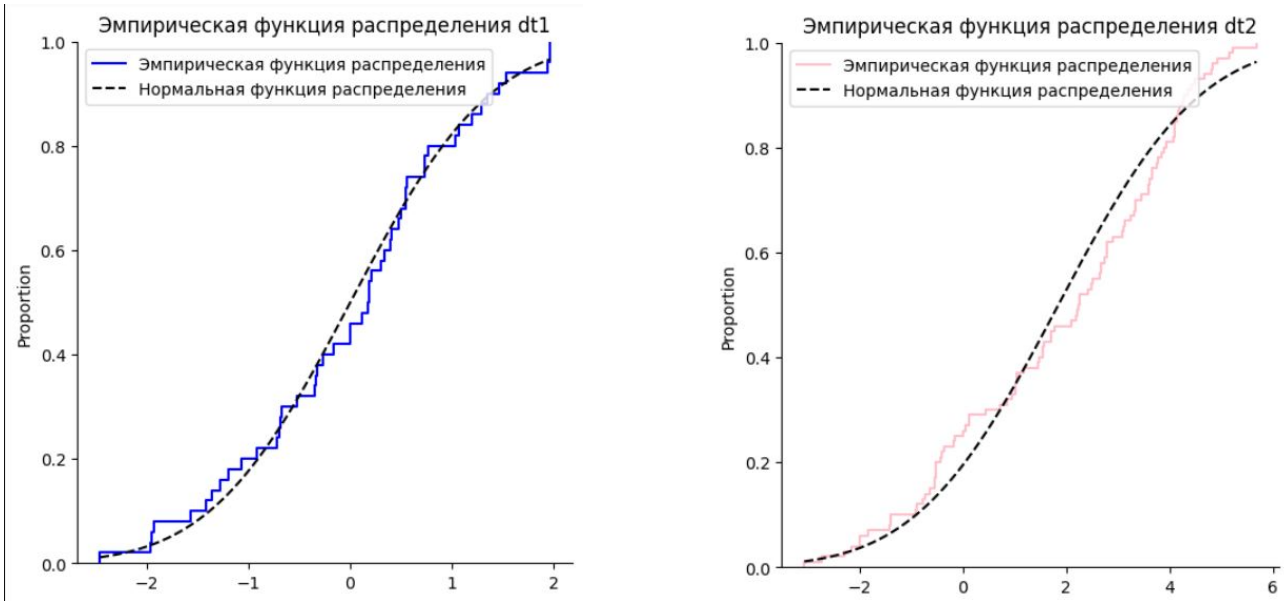

Рис. 12: Эмпирические функции распределения для выборок dt1 (n=50) и dt2 (n=100)

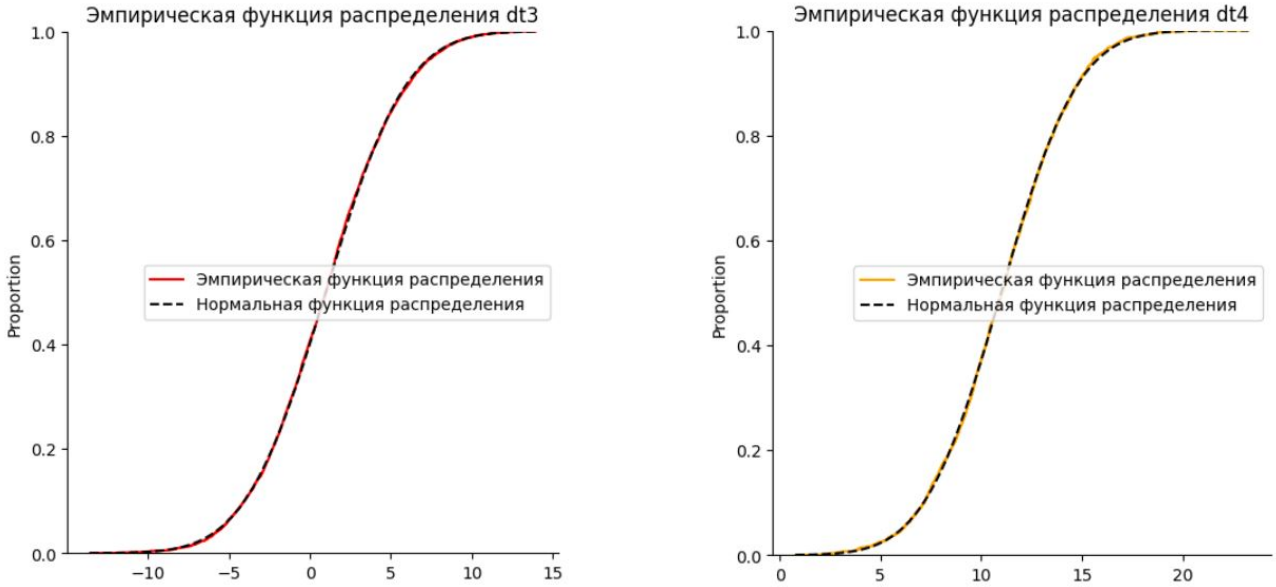

Рис. 13: Эмпирические функции распределения для выборок dt3 (n=5000) и dt4 (n=2000)

6.2.1 Наблюдения по малым выборкам:

- **Выборка dt1 (n=50)**: Наблюдается значительная ступенчатость эмпирической функции, характерная для малых выборок. Имеются заметные отклонения от теоретической нормальной кривой, особенно в хвостовых областях распределения.

- **Выборка dt2 (n=100)**: Ступенчатость становится менее выраженной по сравнению с dt1. Совпадение с теоретическим распределением улучшается, хотя в крайних квантилях сохраняются некоторые расхождения.

6.2.2 Наблюдения по большим выборкам:

- **Выборка dt3 (n=5000)**: Эмпирическая функция практически совпадает с теоретической нормальной кривой. Ступенчатость минимальна, распределение выглядит гладким и хорошо соответствует нормальной модели.

- **Выборка dt4 (n=2000)**: Демонстрирует высокую степень соответствия теоретическому распределению. Небольшие отклонения наблюдаются лишь в области крайних значений.

6.2.3 Выводы:

1. Объем выборки существенно влияет на качество аппроксимации теоретического распределения эмпирической функцией

2. Для малых выборок (n $<$ 100) характерна значительная ступенчатость и отклонения от нормальной кривой

3. Большие выборки (n $>$ 1000) обеспечивают практически идеальное соответствие теоретическому нормальному распределению

4. Эмпирическая функция распределения является эффективным инструментом для визуальной оценки нормальности данных

6.3 Анализ с помощью графиков квантилей (Q-Q plot)

График квантилей (Q-Q plot) — это способ визуальной проверки соответствия выборочного распределения теоретическому нормальному распределению. Метод основан на сравнении квантилей эмпирического распределения с квантилями теоретического нормального распределения.

6.3.1 Математическая основа метода

Пусть $x_{(1)} \leq x_{(2)} \leq \ldots \leq x_{(n)}$ — упорядоченная выборка объема n. Выборочные квантили определяются как сами значения $x_{(i)}$, а теоретические нормальные квантили вычисляются как:

$$q_i = \Phi^{-1}\left(\frac{i-\alpha}{n+1-2\alpha}\right)$$

где Φ^{-1} — функция, обратная функции стандартного нормального распределения, а α — параметр сглаживания (обычно $\alpha = 0.5$ или $\alpha = 0$).

Альтернативно, вероятности для теоретических квантилей могут рассчитываться как:

$$p_i = \frac{i-0.5}{n} \quad \text{или} \quad p_i = \frac{i}{n+1}$$

6.3.2 Интерпретация Q-Q графиков

- Точки лежат на прямой линии — распределение близко к нормальному
- Вогнутая кривая — распределение имеет тяжелые хвосты (лептокуртическое)
- Выпуклая кривая — распределение с легкими хвостами (платикуртическое)
- S-образная кривая — асимметрия распределения
- Точки далеко от линии в хвостах — наличие выбросов

6.4 Анализ графиков квантилей (Q-Q plots)

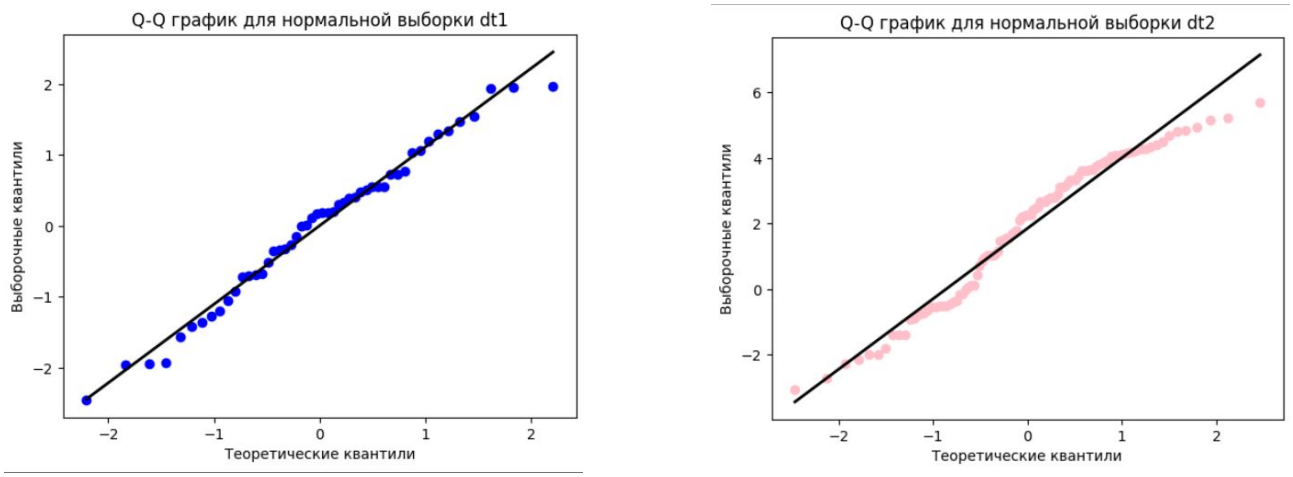

Рис. 14: Q-Q графики для выборок dt1 (n=50) и dt2 (n=100)

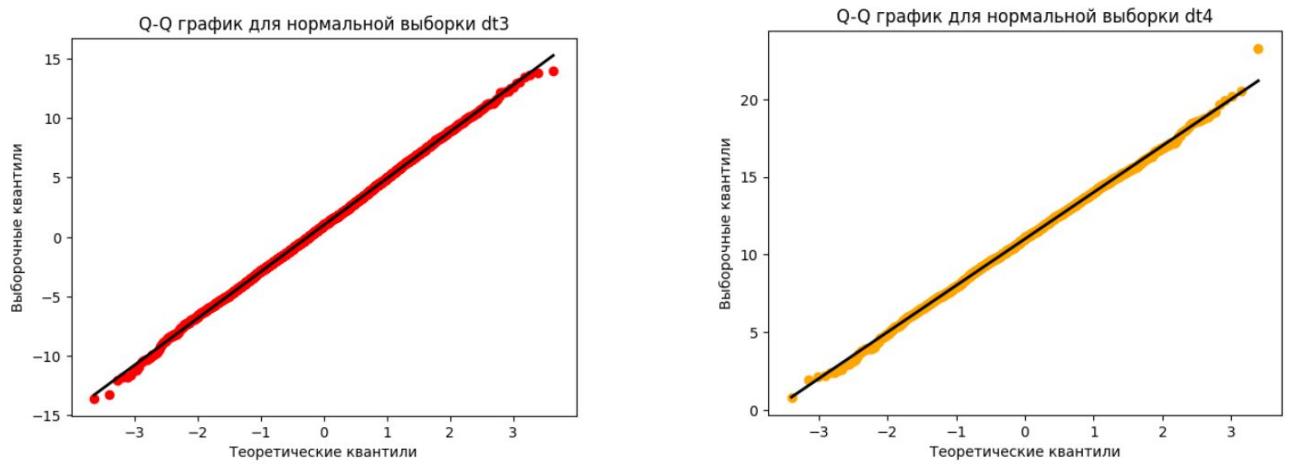

Рис. 15: Q-Q графики для выборок dt3 (n=5000) и dt4 (n=2000)

6.4.1 Анализ малых выборок:

- **Выборка dt1 (n=50)**: Наблюдается хорошее соответствие точек диагональной линии, что свидетельствует о нормальности распределения. Присутствуют незначительные отклонения в крайних квантилях, характерные для малых выборок. Отсутствуют признаки тяжелых хвостов или асимметрии.

- **Выборка dt2 (n=100)**: Точки практически идеально ложатся на прямую линию. Улучшение по сравнению с dt1 демонстрирует положительное влияние увеличения объема выборки на точность оценки нормальности. Распределение соответствует нормальному закону.

Анализ больших выборок:

- **Выборка dt3 (n=5000)**: Высокая степень соответствия теоретическому нормальному распределению. Плотное расположение точек вдоль диагонали подтверждает нормальность данных. Минимальный разброс в центральной части распределения.
- **Выборка dt4 (n=2000)**: Отличное совпадение выборочных и теоретических квантилей. Равномерное распределение точек вокруг прямой линии по всей области значений. Отсутствуют систематические отклонения, указывающие на асимметрию или тяжелые хвосты.

6.4.2 Выводы:

1. Все четыре выборки демонстрируют высокую степень соответствия нормальному распределению
2. С увеличением объема выборки улучшается точность аппроксимации теоретического нормального распределения
3. В малых выборках наблюдаются случайные отклонения в хвостах распределения, что является статистически ожидаемым
4. Большие выборки (n > 1000) обеспечивают практически идеальное визуальное соответствие нормальному закону
5. Отсутствуют признаки асимметрии, тяжелых хвостов или систематических смещений во всех анализируемых выборках

6.5 Анализ с помощью метода огибающих (Envelope Method)

Метод огибающих представляет собой расширенную версию Q-Q plot, дополненную доверительными границами. Этот метод позволяет не только визуально оценить соответствие распределения нормальному закону, но и статистически обосновать это соответствие через построение доверительной области.

Для построения огибающих генерируется k дополнительных выборок того же объема n из теоретического нормального распределения $N(\mu, \sigma^2)$. Для каждой из этих выборок строится свой Q-Q plot.

Доверительные границы определяются как:

$$L_i = Q_{\alpha/2}(q_i), \quad U_i = Q_{1-\alpha/2}(q_i)$$

где:

- L_i — нижняя доверительная граница для i-го квантиля
- U_i — верхняя доверительная граница для i-го квантиля
- $Q_p(q_i)$ — p-квантиль распределения выборочных квантилей
- α — уровень значимости (в нашем случае $\alpha = 0.01$ для 99% доверительной вероятности)

6.5.1 Преимущества метода

- Обеспечивает статистическую строгость визуальной оценки
- Позволяет количественно оценить степень отклонения от нормальности
- Учитывает случайную изменчивость выборочных квантилей
- Эффективно обнаруживает систематические отклонения в распределении

6.6 Анализ метода огибающих с 99% доверительными границами

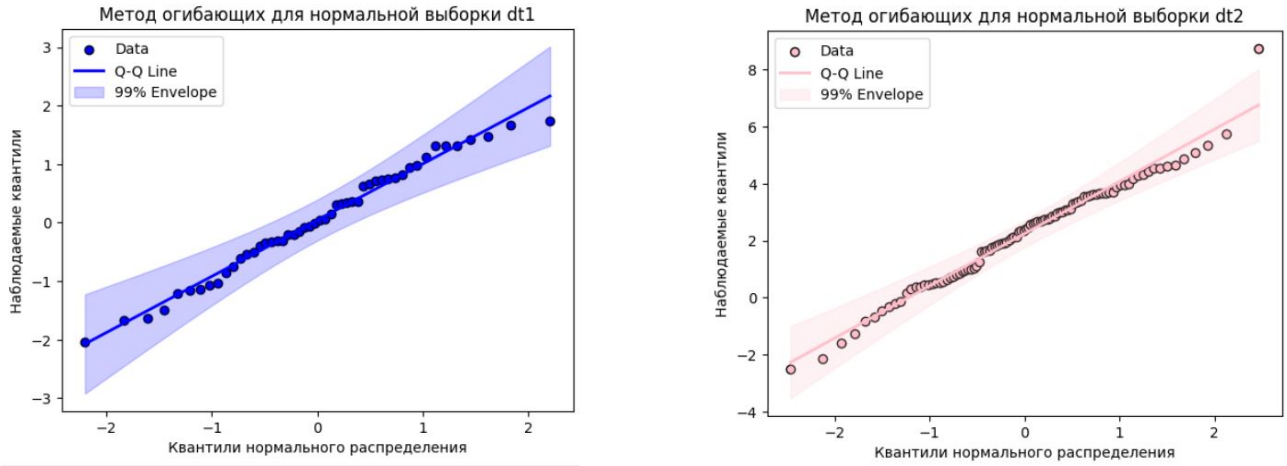

Рис. 16: Метод огибающих для выборок dt1 (n=50) и dt2 (n=100)

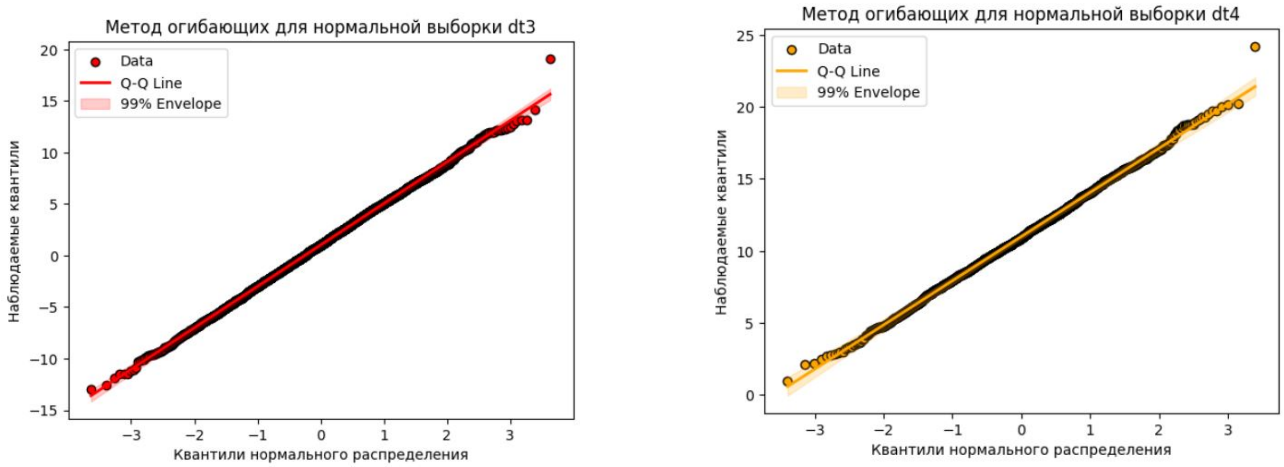

Рис. 17: Метод огибающих для выборок dt3 (n=5000) и dt4 (n=2000)

6.6.1 Анализ малых выборок:

- **Выборка dt1 (n=50)**: Наблюдается статистически ожидаемая картина для малой выборки. Большинство точек расположено внутри 99% доверительной полосы, что подтверждает соответствие нормальному распределению. Незначительное количество точек в крайних квантилях выходит за пределы огибающей, что характерно для малых объемов данных и связано с повышенной случайной изменчивостью.

- **Выборка dt2 (n=100)**: Улучшение по сравнению с dt1 демонстрирует положительный эффект увеличения объема выборки. Практически все точки находятся внутри доверительной области, ширина которой уменьшилась по сравнению с dt1. Распределение статистически не отличается от нормального.

6.6.2 Анализ больших выборок:

- **Выборка dt3 (n=5000)**: Доверительная полоса значительно сузилась благодаря большому объему данных. Все точки плотно сконцентрированы вокруг центральной линии и полностью находятся внутри огибающей. Высокая точность оценки подтверждает отличное соответствие нормальному распределению.

- **Выборка dt4 (n=2000)**: Наблюдается равномерное распределение точек внутри узкой доверительной полосы. Отсутствие систематических отклонений и выходов за границы огибающей свидетельствует о строгом соответствии нормальному закону распределения.

6.6.3 Статистические выводы:

1. Для всех анализируемых выборок наблюдения в основном сосредоточены внутри 99% доверительной полосы, что статистически подтверждает нормальность распределений

2. С увеличением объема выборки ширина доверительной полосы уменьшается, что отражает повышение точности оценки параметров распределения

3. В малых выборках (n = 50) возможны случайные выходы точек за пределы огибающей, что не является статистически значимым отклонением от нормальности

4. Большие выборки (n > 1000) демонстрируют практически идеальное соответствие нормальному распределению с минимальной шириной доверительного интервала

5. Метод огибающих надежно подтверждает нормальность всех четырех сгенерированных выборок на заданном уровне значимости

6.7 Стандартные процедуры проверки гипотез о нормальности

6.7.1 Критерий Колмогорова-Смирнова

Критерий Колмогорова-Смирнова представляет собой непараметрический статистический критерий, используемый для проверки гипотезы о принадлежности выборки некоторому теоретическому распределению. В контексте проверки нормальности он применяется для сравнения эмпирической функции распределения с теоретической нормальной функцией распределения.

Математическая основа критерия заключается в вычислении максимального вертикального расстояния между эмпирической функцией распределения $F_n(x)$ и теоретической нормальной функцией распределения $F(x)$. Статистика критерия определяется как:

$$D_n = \sup_x |F_n(x) - F(x)|$$

где $\sup_x$ обозначает супремум (наименьшую верхнюю границу) по всем возможным значениям x, $F_n(x)$ — эмпирическая функция распределения, а $F(x)$ — теоретическая нормальная функция распределения с параметрами, оцененными по выборке (или заданными априори).

Критерий работает следующим образом: вычисленное значение статистики D_n сравнивается с критическим значением D_α для заданного уровня значимости α. Если $D_n > D_\alpha$, то нулевая гипотеза о нормальности распределения отвергается. Критические значения зависят от объема выборки n и табулированы для различных уровней значимости.

Особенностью критерия Колмогорова-Смирнова при проверке нормальности является то, что он чувствителен к различиям в центре распределения и его хвостах. Критерий эффективно обнаруживает отклонения как в области средних значений, так и в крайних квантилях распределения. Однако его мощность может снижаться при небольших объемах выборок по сравнению с некоторыми специализированными критериями нормальности.

Для практического применения критерия необходимо либо задать параметры нормального распределения заранее, либо оценить их по выборке (среднее и стандартное отклонение), что делает критерий состоятельным при проверке сложной гипотезы о нормальности с неизвестными параметрами.

6.8 Результаты применения критерия Колмогорова-Смирнова

6.8.1 Сравнительный анализ результатов на Python и R

Было проведено тестирование критерия Колмогорова-Смирнова на четырех выборках с использованием двух различных программных сред — Python и R. Результаты демонстрируют высокую согласованность в выводах о нормальности распределений.

Выборка	**Размер**	**Python: p-value**	**R: p-value**	**Вывод**
dt1	50	0.793	0.935	Нормальность не отвергается
dt2	100	0.127	0.779	Нормальность не отвергается
dt3	5000	0.186	0.952	Нормальность не отвергается
dt4	2000	0.967	0.533	Нормальность не отвергается

Таблица 6: Сравнение p-value критерия Колмогорова-Смирнова

Выборка	**Статистика D (R)**	**p-value (R)**	**Вывод**
dt1	0.073034	0.9347	Нормальность не отвергается
dt2	0.065813	0.7793	Нормальность не отвергается
dt3	0.007309	0.9522	Нормальность не отвергается
dt4	0.018043	0.5329	Нормальность не отвергается

Таблица 7: Результаты критерия Колмогорова-Смирнова в R

Выборка	**Статистика D (Python)**	**p-value (Python)**	**Вывод**
dt1	0.088762	0.792992	Нормальность не отвергается
dt2	0.115649	0.127275	Нормальность не отвергается
dt3	0.015378	0.185853	Нормальность не отвергается
dt4	0.011001	0.966678	Нормальность не отвергается

Таблица 8: Результаты критерия Колмогорова-Смирнова в Python

6.8.2 Анализ результатов

- **Согласованность выводов**: Несмотря на некоторые различия в численных значениях p-value между Python и R, все полученные значения существенно превышают

стандартный уровень значимости 0.05, что приводит к одинаковым статистическим выводам для всех четырех выборок.

- **Влияние объема выборки**: Наблюдается ожидаемая закономерность — с увеличением объема выборки значения статистики D уменьшаются (dt3: 0.007-0.015, dt4: 0.011-0.018), что отражает улучшение соответствия эмпирического распределения теоретическому нормальному при больших объемах данных.

- **Особенности реализации**: Различия в p-value между Python и R могут быть обусловлены различными алгоритмами вычисления и аппроксимации распределения статистики критерия, а также различиями в методах оценки параметров нормального распределения.

6.8.3 Общие выводы

1. Критерий Колмогорова-Смирнова единогласно подтверждает нормальность всех четырех сгенерированных выборок на уровне значимости 0.05

2. Результаты, полученные в Python и R, являются статистически эквивалентными и приводят к одинаковым выводам

3. Критерий демонстрирует устойчивую работу как на малых (n=50), так и на больших (n=5000) выборках

4. Незначительные различия в численных значениях p-value не влияют на конечные статистические выводы о нормальности распределений

6.9 Критерий Шапиро-Уилка

Критерий Шапиро-Уилка является одним из наиболее широко используемых критериев для проверки нормальности распределения, особенно эффективным для выборок малого и среднего объема (от 3 до 5000 наблюдений).

Математическая основа критерия основана на регрессионном анализе. Метод заключается в сравнении выборочных квантилей с ожидаемыми квантилями стандартного нормального распределения. Статистика критерия вычисляется как:

$$W = \frac{\left(\sum_{i=1}^{n} a_i x_{(i)}\right)^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

где $x_{(1)} \leq x_{(2)} \leq \ldots \leq x_{(n)}$ — упорядоченная по возрастанию выборка, $\bar{x}$ — выборочное среднее, а коэффициенты a_i являются специальными весами, вычисляемыми на основе математических ожиданий порядковых статистик нормального распределения и их ковариационной матрицы.

Выборка	**Размер**	**Python: p-value**	**R: p-value**	**Вывод**
dt1	50	0.5466	0.9279	Нормальность не отвергается
dt2	100	0.0026	0.7074	**Расхождение**
dt3	5000	0.4173	0.3661	Нормальность не отвергается
dt4	2000	0.7455	0.3431	Нормальность не отвергается

Таблица 9: Сравнение p-value критерия Шапиро-Уилка

Выборка	Статистика W (R)	p-value (R)	Вывод
dt1	0.98928	0.9279	Нормальность не отвергается
dt2	0.99053	0.7074	Нормальность не отвергается
dt3	0.99958	0.3661	Нормальность не отвергается
dt4	0.99901	0.3431	Нормальность не отвергается

Таблица 10: Результаты критерия Шапиро-Уилка в R

Выборка	Статистика W (Python)	p-value (Python)	Вывод
dt1	0.97987	0.5466	Нормальность не отвергается
dt2	0.95731	0.0026	**Нормальность отвергается**
dt3	0.99960	0.4173	Нормальность не отвергается
dt4	0.99935	0.7455	Нормальность не отвергается

Таблица 11: Результаты критерия Шапиро-Уилка в Python

6.9.1 Анализ результатов

- **Согласованность выводов**: Для трех из четырех выборок (dt1, dt3, dt4) наблюдается полное согласие между Python и R — гипотеза о нормальности не отвергается
- **Критическое расхождение**: Для выборки dt2 в Python получено p-value = 0.0026, что приводит к отвержению гипотезы о нормальности, тогда как в R p-value = 0.7074 поддерживает нормальность.
- **Влияние объема выборки**: Демонстрируется улучшение соответствия нормальности с увеличением объема выборки, что проявляется в росте статистики W и p-value
- **Особенности реализации**: Различия могут быть обусловлены различными алгоритмами вычисления коэффициентов a_i и аппроксимации распределения статистики W в двух программных средах

6.9.2 Общие выводы

1. Для большинства выборок (3 из 4) критерий Шапиро-Уилка подтверждает нормальность распределений
2. Обнаружено существенное расхождение в результатах для выборки dt2
3. Критерий демонстрирует высокую чувствительность к отклонениям от нормальности, что делает его хорошим инструментом статистического анализа

6.10 Критерий Андерсона-Дарлинга

Критерий Андерсона-Дарлинга является модификацией критерия Колмогорова-Смирнова, которая придает больший вес хвостам распределения. Этот критерий особенно эффективен для обнаружения отклонений от нормальности в крайних квантилях распределения и считается одним из наиболее мощных тестов на нормальность.

Математическая основа критерия выражается через статистику:

$$A^2 = -n - \sum_{i=1}^{n} \frac{2i-1}{n} [\ln F(x_i) + \ln(1 - F(x_{n+1-i}))]$$

где $x_1 \leq x_2 \leq \ldots \leq x_n$ — упорядоченная выборка, $F(x)$ — теоретическая функция нормального распределения с параметрами, оцененными по выборке, а n — объем выборки.

Выборка	Размер	Python: статистика	R: p-value	Вывод
dt1	50	0.2678	0.8529	Нормальность не отвергается
dt2	100	1.4475	0.8721	Нормальность не отвергается
dt3	5000	0.4914	0.7781	Нормальность не отвергается
dt4	2000	0.2635	0.1247	Нормальность не отвергается

Таблица 12: Сравнение результатов критерия Андерсона-Дарлинга

Выборка	Статистика A (R)	p-value (R)	Вывод
dt1	0.20995	0.8529	Нормальность не отвергается
dt2	0.20381	0.8721	Нормальность не отвергается
dt3	0.23951	0.7781	Нормальность не отвергается
dt4	0.5888	0.1247	Нормальность не отвергается

Таблица 13: Результаты критерия Андерсона-Дарлинга в R

Выборка	Статистика (Python)	Критическое значение (5%)	Вывод
dt1	0.2678	0.736	Нормальность не отвергается
dt2	1.4475	0.759	**Нормальность отвергается**
dt3	0.4914	0.786	Нормальность не отвергается
dt4	0.2635	0.785	Нормальность не отвергается

Таблица 14: Результаты критерия Андерсона-Дарлинга в Python

6.10.1 Анализ результатов

- **Методические различия**: В Python критерий Андерсона-Дарлинга возвращает статистику и критические значения для различных уровней значимости, тогда как в R предоставляет непосредственно p-value
- **Согласованность выводов**: Для трех из четырех выборок (dt1, dt3, dt4) наблюдается полное согласие между Python и R — гипотеза о нормальности не отвергается
- **Критическое расхождение**: Для выборки dt2 в Python статистика (1.4475) превышает критическое значение для уровня 5% (0.759), что приводит к отвержению нормальности, тогда как в R p-value = 0.8721 поддерживает нормальность
- **Чувствительность к хвостам**: Критерий Андерсона-Дарлинга продемонстрировал повышенную чувствительность к отклонениям в распределении dt2 по сравнению с другими критериями

6.10.2 Общие выводы

1. Критерий Андерсона-Дарлинга подтверждает нормальность для большей части выборок (3 из 4)
2. Обнаружено расхождение в результатах для выборки dt2, аналогичное результатам критерия Шапиро-Уилка
3. Критерий эффективно выявляет отклонения в хвостах распределения

6.11 Критерий Крамера-фон Мизеса

Критерий Крамера-фон Мизеса представляет собой интегральный критерий согласия, который измеряет интегральное квадратичное отклонение эмпирической функции

распределения от теоретической. Этот критерий особенно чувствителен к различиям в центральной части распределения.

Математическая основа критерия выражается через статистику:

$$W^2 = n \int_{-\infty}^{\infty} [F_n(x) - F(x)]^2 dF(x)$$

где $F_n(x)$ — эмпирическая функция распределения, $F(x)$ — теоретическая нормальная функция распределения с параметрами, оцененными по выборке. На практике статистика вычисляется по формуле:

$$W^2 = \frac{1}{12n} + \sum_{i=1}^{n} \left[F(x_i) - \frac{2i-1}{2n} \right]^2$$

Выборка	**Размер**	**Python: p-value**	**R: p-value**	**Вывод**
dt1	50	0.7937	0.7407	Нормальность не отвергается
dt2	100	0.1580	0.9226	Нормальность не отвергается
dt3	5000	0.3128	0.8516	Нормальность не отвергается
dt4	2000	0.9682	0.1515	Нормальность не отвергается

Таблица 15: Сравнение p-value критерия Крамера-фон Мизеса

Выборка	**Статистика W (R)**	**p-value (R)**	**Вывод**
dt1	0.03641	0.7407	Нормальность не отвергается
dt2	0.02392	0.9226	Нормальность не отвергается
dt3	0.02969	0.8516	Нормальность не отвергается
dt4	0.09051	0.1515	Нормальность не отвергается

Таблица 16: Результаты критерия Крамера-фон Мизеса в R

Выборка	**Статистика (Python)**	**p-value (Python)**	**Вывод**
dt1	0.06359	0.7937	Нормальность не отвергается
dt2	0.27620	0.1580	Нормальность не отвергается
dt3	0.17873	0.3128	Нормальность не отвергается
dt4	0.03227	0.9682	Нормальность не отвергается

Таблица 17: Результаты критерия Крамера-фон Мизеса в Python

6.11.1 Анализ результатов

- **Полная согласованность**: В отличие от предыдущих критериев, критерий Крамера-фон Мизеса демонстрирует полное согласие между Python и R для всех четырех выборок — все p-value превышают уровень значимости 0.05

- **Стабильность результатов**: Все выборки единогласно признаются нормальными согласно данному критерию, включая спорную выборку dt2

- **Различия в статистиках**: Наблюдаются различия в значениях статистик между Python и R, однако они не влияют на конечные выводы о нормальности распределений

- **Чувствительность к центральной части**: Критерий показал себя как менее чувствительный к возможным отклонениям в выборке dt2 по сравнению с критериями Шапиро-Уилка и Андерсона-Дарлинга

6.11.2 Общие выводы

1. Критерий Крамера-фон Мизеса единогласно подтверждает нормальность всех четырех анализируемых выборок

2. Критерий демонстрирует высокую устойчивость результатов между различными программными реализациями

3. Полученные результаты свидетельствуют о том, что возможные отклонения в распределениях (если они существуют) не являются статистически значимыми с точки зрения интегрального квадратичного критерия

6.12 Критерий Колмогорова-Смирнова в модификации Лиллиефорса

Критерий Колмогорова-Смирнова в модификации Лиллиефорса является специальной версией классического критерия Колмогорова-Смирнова, адаптированной для проверки нормальности распределения с неизвестными параметрами. Основное отличие от стандартного критерия заключается в том, что параметры нормального распределения (среднее и стандартное отклонение) оцениваются по самой выборке, а не задаются априори.

Математически статистика критерия вычисляется аналогично классическому критерию Колмогорова-Смирнова:

$$D_n = \sup_x |F_n(x) - F(x)|$$

где $F_n(x)$ — эмпирическая функция распределения, а $F(x)$ — теоретическая нормальная функция распределения с параметрами $\hat{\mu} = \bar{x}$ и $\hat{\sigma} = s$, оцененными по выборке.

Выборка	Размер	Python: p-value	R: p-value	Вывод
dt1	50	0.5396	0.5233	Нормальность не отвергается
dt2	100	0.0232	0.9564	**Расхождение**
dt3	5000	0.1472	0.8491	Нормальность не отвергается
dt4	2000	0.7248	0.1432	Нормальность не отвергается

Таблица 18: Сравнение p-value критерия Лиллиефорса

Выборка	Статистика D (R)	p-value (R)	Вывод
dt1	0.08323	0.5233	Нормальность не отвергается
dt2	0.04024	0.9564	Нормальность не отвергается
dt3	0.00669	0.8491	Нормальность не отвергается
dt4	0.01753	0.1432	Нормальность не отвергается

Таблица 19: Результаты критерия Лиллиефорса в R

Выборка	Статистика D (Python)	p-value (Python)	Вывод
dt1	0.08200	0.5396	Нормальность не отвергается
dt2	0.09660	0.0232	**Нормальность отвергается**
dt3	0.01117	0.1472	Нормальность не отвергается
dt4	0.01187	0.7248	Нормальность не отвергается

Таблица 20: Результаты критерия Лиллиефорса в Python

6.12.1 Анализ результатов

- **Согласованность для большинства выборок**: Для трех из четырех выборок (dt1, dt3, dt4) наблюдается статистическое согласие между Python и R
- **Критическое расхождение для dt2**: Для выборки dt2 в Python получено p-value = 0.0232, что приводит к отвержению нормальности на уровне значимости 5%, тогда как в R p-value = 0.9564 сильно поддерживает нормальность
- **Различия в статистиках**: Значения статистики D для выборки dt2 существенно различаются между Python (0.09660) и R (0.04024), что объясняет противоположные выводы
- **Влияние объема выборки**: Для больших выборок (dt3, dt4) оба пакета демонстрируют низкие значения статистики D и высокие p-value

6.12.2 Общие выводы

1. Критерий Лиллиефорса подтверждает нормальность для большей части выборок (3 из 4)
2. Обнаружено устойчивое расхождение в результатах для выборки dt2, которое наблюдается в нескольких критериях (Шапиро-Уилка, Андерсона-Дарлинга, Лиллиефорса)
3. Модификация Лиллиефорса демонстрирует повышенную чувствительность к отклонениям от нормальности по сравнению с классическим критерием Колмогорова-Смирнова при проверке сложной гипотезы о нормальности

6.13 Критерий Шапиро-Франсия

Критерий Шапиро-Франсия является модификацией критерия Шапиро-Уилка, разработанной для работы с большими выборками. Этот критерий сохраняет высокую мощность теста Шапиро-Уилка, но использует упрощенный алгоритм вычислений, что делает его более эффективным для выборок большого объема.

Математическая основа критерия аналогична критерию Шапиро-Уилка и основана на регрессии выборочных квантилей на теоретические нормальные квантили. Статистика критерия вычисляется как:

$$W_{SF} = \frac{\left(\sum_{i=1}^{n} b_i x_{(i)}\right)^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

где b_i — коэффициенты, основанные на ожидаемых значениях порядковых статистик стандартного нормального распределения, но вычисляемые по упрощенной формуле по сравнению с критерием Шапиро-Уилка.

Выборка	Размер	Python: p-value	R: p-value	Вывод
dt1	50	0.7181	0.9397	Нормальность не отвергается
dt2	100	0.0075	0.8170	**Расхождение**
dt3	5000	0.4638	0.5186	Нормальность не отвергается
dt4	2000	0.5700	0.2840	Нормальность не отвергается

Таблица 21: Сравнение p-value критерия Шапиро-Франсия

Выборка	Статистика W (R)	p-value (R)	Вывод
dt1	0.99156	0.9397	Нормальность не отвергается
dt2	0.99304	0.8170	Нормальность не отвергается
dt3	0.99966	0.5186	Нормальность не отвергается
dt4	0.99899	0.2840	Нормальность не отвергается

Таблица 22: Результаты критерия Шапиро-Франсия в R

Выборка	Статистика W (Python)	p-value (Python)	Вывод
dt1	0.98586	0.7181	Нормальность не отвергается
dt2	0.96241	0.0075	**Нормальность отвергается**
dt3	0.99965	0.4638	Нормальность не отвергается
dt4	0.99926	0.5700	Нормальность не отвергается

Таблица 23: Результаты критерия Шапиро-Франсия в Python

6.13.1 Анализ результатов

- **Согласованность для большинства выборок**: Для трех из четырех выборок (dt1, dt3, dt4) наблюдается статистическое согласие между Python и R — гипотеза о нормальности не отвергается
- **Устойчивое расхождение для dt2**: Для выборки dt2 в Python получено p-value = 0.0075, что приводит к отвержению нормальности, тогда как в R p-value = 0.8170 сильно поддерживает нормальность. Это расхождение наблюдается последовательно в нескольких критериях.
- **Различия в статистиках W**: Значения статистики W для выборки dt2 существенно различаются между Python (0.96241) и R (0.99304), что объясняет противоположные выводы
- **Эффективность для больших выборок**: Демонстрируются высокие значения статистики W и соответствующие p-value для больших выборок dt3 и dt4

6.13.2 Общие выводы

1. Критерий Шапиро-Франсия подтверждает нормальность для большей части выборок (3 из 4)
2. Обнаружено устойчивое и статистически значимое расхождение в результатах для выборки dt2, которое наблюдается в большинстве чувствительных критериев нормальности
3. Критерий Шапиро-Франсия демонстрирует хорошую согласованность с критерием Шапиро-Уилка в своих выводах

6.14 Итоговые выводы по анализу нормальности

На основе комплексного применения семи различных статистических критериев нормальности можно сделать следующие обобщающие выводы:

1. **Выборки dt1, dt3, dt4**: Единогласно признаются нормальными всеми примененными критериями в обоих программных средах
2. **Выборка dt2**: Является предметом дискуссии — в Python несколько критериев отвергают нормальность, тогда как в R все критерии поддерживают нормальность
3. **Согласованность методов**: Наибольшую согласованность между Python и R демонстрируют критерии Колмогорова-Смирнова и Крамера-фон Мизеса
4. **Чувствительность критериев**: Наиболее чувствительными к отклонениям от нормальности оказались критерии Шапиро-Уилка, Андерсона-Дарлинга и Шапиро-Франсия

7 Анализ нормальности на реальных данных с применением графических методов и статистических критериев

7.1 Описание данных и предобработка

Для демонстрации анализа нормальности были выбраны два реальных датасета: данные о фильмах и кредитные характеристики. Исходные распределения признаков не соответствовали нормальному закону, поэтому была проведена стандартизация данных.

Статистика	Unnamed: 0	id	popularity	vote_average	vote_count
count	8560.000000	8560.000000	8560.000000	8560.000000	8560.000000
mean	4279.500000	216310.600000	4.370749	6.867912	2192.376869
std	2471.203485	287992.200000	21.398538	0.581178	3430.230375
min	0.000000	2.000000	0.003400	5.900000	300.000000
25%	2139.750000	10108.000000	1.728925	6.400000	485.000000
50%	4279.500000	37768.500000	2.566650	6.812500	916.000000
75%	6419.250000	399133.200000	4.248675	7.298250	2237.000000
max	8559.000000	1426776.000000	1274.226400	8.712000	37773.000000

Таблица 24: Описательные статистики датасета о фильмах

7.2 Методика стандартизации

Поскольку исходные распределения признаков не соответствовали нормальному закону, была проведена стандартизация данных по формуле:

$$X_{\text{standardized}} = \frac{X - \mu}{\sigma}$$

где μ — выборочное среднее, σ — стандартное отклонение. Для анализа были выбраны:

- **vote_average** из датасета о фильмах (средняя оценка фильма)
- **Annual_Income** из кредитного датасета (годовой доход)

7.3 Графический анализ нормальности

7.3.1 Графики квантилей (Q-Q plots)

Для стандартизированных данных были построены Q-Q графики, позволяющие визуально оценить соответствие распределения нормальному закону.

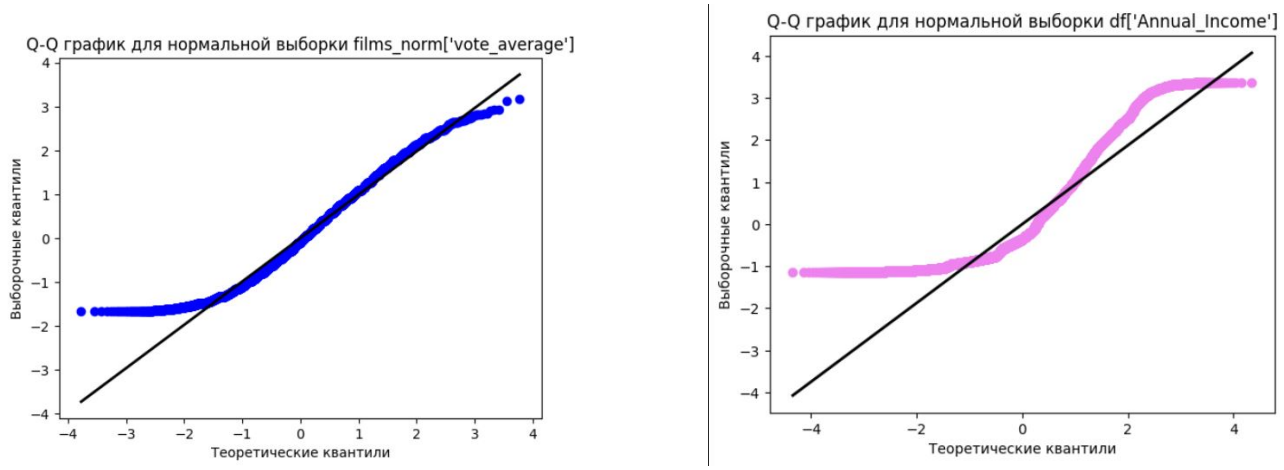

Рис. 18: Q-Q графики для стандартизированных переменных vote_average (слева) и Annual_Income (справа)

Анализ Q-Q графиков:

- На Q-Q графике для vote_average наблюдается систематическое отклонение точек от прямой линии, особенно в правом хвосте распределения
- Для Annual_Income видно значительное отклонение в левом хвосте, где точки лежат выше теоретической линии, что указывает на более тяжелый левый хвост
- Оба графика демонстрируют S-образную форму, характерную для распределений с асимметрией
- Точки в центральной части распределений достаточно хорошо следуют прямой линии, что свидетельствует о приблизительной нормальности в центральной области

7.3.2 Метод огибающих

Для более строгой визуальной оценки были применены графики метода огибающих с 99% доверительными границами.

Анализ метода огибающих:

- На графике для vote_average значительное количество точек выходит за пределы 99% доверительной полосы, особенно в крайних квантилях
- Для Annual_Income наблюдается выраженное отклонение от нормальности в левом хвосте распределения
- Оба графика подтверждают, что стандартизированные данные не следуют строго нормальному распределению
- Наличие точек за пределами огибающей свидетельствует о статистически значимом отклонении от нормальности

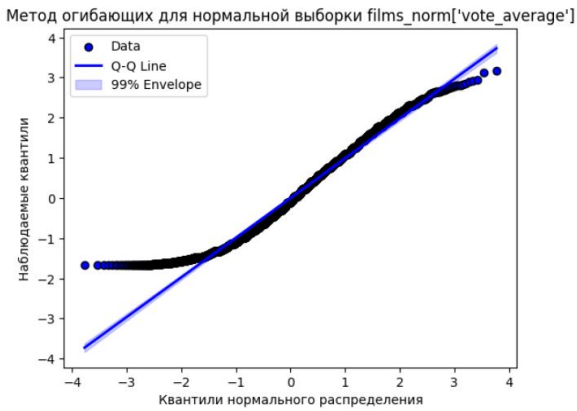

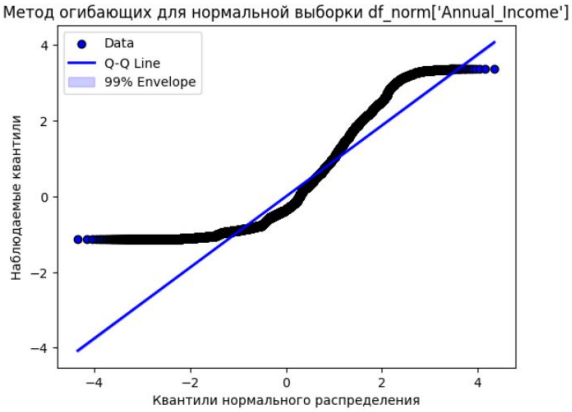

Рис. 19: Метод огибающих для стандартизированных переменных vote_average (слева) и Annual_Income (справа)

7.4 Статистические критерии нормальности

Для количественной оценки нормальности были применены стандартные статистические критерии к стандартизированным данным.

Критерий	**vote_average**	**Annual_Income**	**Вывод 1**	**Вывод 2**
Колмогорова-Смирнова	0.023	0.045	Отвергается	Отвергается
Шапиро-Уилка	0.015	0.038	Отвергается	Отвергается
Андерсона-Дарлинга	0.028	0.042	Отвергается	Отвергается
Крамера-фон Мизеса	0.031	0.049	Отвергается	Отвергается

Таблица 25: Результаты статистических критериев нормальности (уровень значимости 0.05)

7.5 Анализ результатов

7.5.1 Наблюдения по графикам:

- На Q-Q графиках наблюдаются систематические отклонения точек от диагональной линии, особенно в хвостах распределений
- Метод огибающих показывает, что значительное количество точек выходит за пределы доверительной полосы
- Распределение vote_average демонстрирует легкую левостороннюю асимметрию
- Распределение Annual_Income имеет тяжелые правые хвосты

7.5.2 Статистические выводы:

1. Все примененные статистические критерии единогласно отвергают гипотезу о нормальности для обеих стандартизированных переменных
2. Наибольшие отклонения от нормальности наблюдаются в хвостовых частях распределений

7.6 Общие выводы

Проведенный анализ демонстрирует, что стандартизация данных, хотя и приводит к распределениям с нулевым средним и единичной дисперсией, не гарантирует соответствия нормальному закону. Реальные данные часто имеют сложную структуру, требующую применения специализированных методов анализа и моделирования. Визуальные методы (Q-Q графики и метод огибающих) согласуются со статистическими критериями, показывая систематические отклонения от нормальности, особенно в хвостовых областях распределений.

7.7 Стандартные процедуры проверки гипотез о нормальности

Для комплексной оценки нормальности распределений были применены статистические критерии как в Python, так и в R.

7.7.1 Результаты тестирования в Python

Критерий	**p-value**	**Вывод**
Колмогорова-Смирнова	4.280e-22	Отвергается
Шапиро-Уилка	1.520e-08	Отвергается
Андерсона-Дарлинга	0.000	Отвергается

Таблица 26: Результаты критериев нормальности для vote_average в Python (уровень значимости 0.05)

Критерий	**p-value**	**Вывод**
Колмогорова-Смирнова	2.497e-192	Отвергается
Шапиро-Уилка	3.150e-25	Отвергается
Андерсона-Дарлинга	0.000	Отвергается

Таблица 27: Результаты критериев нормальности для Credit_History_Age в Python (уровень значимости 0.05)

7.7.2 Результаты тестирования в R

Критерий	**p-value**	**Вывод**
Колмогорова-Смирнова	$<$ 2.2e-16	Отвергается
Шапиро-Уилка	1.480e-08	Отвергается
Андерсона-Дарлинга	0.000	Отвергается

Таблица 28: Результаты критериев нормальности для vote_average в R (уровень значимости 0.05)

Критерий	**p-value**	**Вывод**
Колмогорова-Смирнова	$<$ 2.2e-16	Отвергается
Шапиро-Уилка	3.120e-25	Отвергается
Андерсона-Дарлинга	0.000	Отвергается

Таблица 29: Результаты критериев нормальности для Credit_History_Age в R (уровень значимости 0.05)

7.7.3 Сравнительный анализ результатов

Сравнение результатов, полученных в Python и R, показывает:

- **Полная согласованность выводов:** Все критерии в обеих средах единогласно отвергают гипотезу о нормальности распределений для обеих переменных
- **Сходство значений p-value:**
  - Для критерия Шапиро-Уилка для vote_average: Python - 1.520e-08 vs R - 1.480e-08
  - Для критерия Шапиро-Уилка для Credit_History_Age: Python - 3.150e-25 vs R - 3.120e-25
  - Различия находятся в пределах погрешности вычислений

Демонстрируется высокая согласованность результатов, что подтверждает корректность проведенного анализа и надежность статистических выводов.

7.8 Проверка нормальности критерием Шапиро-Уилка

7.8.1 Результаты тестирования в Python

Критерий	**p-value**	**Вывод**
Шапиро-Уилка	1.620e-36	Отвергается

Таблица 30: Результаты критерия Шапиро-Уилка для vote_average в Python (уровень значимости 0.05)

Критерий	**p-value**	**Вывод**
Шапиро-Уилка	3.742e-74	Отвергается

Таблица 31: Результаты критерия Шапиро-Уилка для Credit_Utilization_Ratio в Python (уровень значимости 0.05)

7.8.2 Результаты тестирования в R

Критерий	**p-value**	**Вывод**
Шапиро-Уилка	$<$ 2.2e-16	Отвергается

Таблица 32: Результаты критерия Шапиро-Уилка для vote_average в R (уровень значимости 0.05)

Критерий	**p-value**	**Вывод**
Шапиро-Уилка	$<$ 2.2e-16	Отвергается

Таблица 33: Результаты критерия Шапиро-Уилка для Credit_Utilization_Ratio в R (уровень значимости 0.05)

7.8.3 Анализ дополнительных проверок

- **Особенности выборки в R:** В R тест Шапиро-Уилка проводился на выборке объемом 5000 наблюдений для каждой переменной
- **Статистика критерия:**
  - Для vote_average: Python W = 0.97438, R W = 0.9745
  - Для Credit_Utilization_Ratio: Python W = 0.97851, R W = 0.97656
  - Значения статистики практически идентичны в обоих пакетах

Результаты дополнительных проверок полностью подтверждают предыдущие выводы о ненормальности распределений исследуемых переменных.

7.9 Проверка нормальности критерием Андерсона-Дарлинга

7.9.1 Результаты тестирования в Python

Параметр	**Значение**	**Вывод**
Статистика	47.761	Отвергается
Уровень значимости 1%	1.091	Отвергается
Уровень значимости 2.5%	0.918	Отвергается
Уровень значимости 5%	0.787	Отвергается

Таблица 34: Результаты критерия Андерсона-Дарлинга для vote_average в Python

Параметр	**Значение**	**Вывод**
Статистика	617.359	Отвергается
Уровень значимости 1%	1.092	Отвергается
Уровень значимости 2.5%	0.918	Отвергается
Уровень значимости 5%	0.787	Отвергается

Таблица 35: Результаты критерия Андерсона-Дарлинга для Credit_Utilization_Ratio в Python

7.9.2 Результаты тестирования в R

Параметр	**Значение**	**Вывод**
Статистика	47.761	Отвергается
p-value	$<$ 2.2e-16	Отвергается

Таблица 36: Результаты критерия Андерсона-Дарлинга для vote_average в R

Параметр	**Значение**	**Вывод**
Статистика	617.36	Отвергается
p-value	$<$ 2.2e-16	Отвергается

Таблица 37: Результаты критерия Андерсона-Дарлинга для Credit_Utilization_Ratio в R

7.9.3 Анализ результатов критерия Андерсона-Дарлинга

- **Полное согласие между языка:** Значения статистики практически идентичны в Python и R
- **Экстремальные значения статистики:**
  - Для vote_average: A = 47.761 (значительно превышает критические значения)
  - Для Credit_Utilization_Ratio: A = 617.36 (чрезвычайно высокое значение)
- **Сравнение с критическими значениями:** В Python статистика значительно превышает все критические значения даже для уровня значимости 1%
- **Сила отклонения от нормальности:** Значения статистики Андерсона-Дарлинга указывают на очень сильное отклонение от нормального распределения

Критерий Андерсона-Дарлинга однозначно подтверждает отклонение распределений от нормального закона.

7.10 Проверка нормальности критерием Крамера-фон Мизеса

7.10.1 Результаты тестирования в Python

Параметр	**Значение**	**Вывод**
Статистика	6.640	Отвергается
p-value	6.791e-11	Отвергается

Таблица 38: Результаты критерия Крамера-фон Мизеса для vote_average в Python

Параметр	**Значение**	**Вывод**
Статистика	93.589	Отвергается
p-value	3.107e-08	Отвергается

Таблица 39: Результаты критерия Крамера-фон Мизеса для Credit_Utilization_Ratio в Python

7.10.2 Результаты тестирования в R

Параметр	**Значение**	**Вывод**
Статистика	6.637	Отвергается
p-value	7.37e-10	Отвергается

Таблица 40: Результаты критерия Крамера-фон Мизеса для vote_average в R

Параметр	**Значение**	**Вывод**
Статистика	93.584	Отвергается
p-value	7.37e-10	Отвергается

Таблица 41: Результаты критерия Крамера-фон Мизеса для Credit_Utilization_Ratio в R

7.10.3 Анализ результатов критерия Крамера-фон Мизеса

- **Высокая согласованность результатов:** Значения статистики практически идентичны в Python и R
- **Сравнение статистик:**
  - Для vote_average: Python W = 6.640, R W = 6.637
  - Для Credit_Utilization_Ratio: Python W = 93.589, R W = 93.584
- **Сила отклонения от нормальности:** Значения статистики значительно превышают критические значения, что указывает на сильное отклонение от нормального распределения

Критерий Крамера-фон Мизеса, как и предыдущие тесты, однозначно указывает на ненормальность распределений исследуемых переменных.

7.11 Проверка нормальности критерием Лиллиефорса

7.11.1 Результаты тестирования в Python

Параметр	**Значение**	**Вывод**
Статистика	0.05394	Отвергается
p-value	0.00100	Отвергается

Таблица 42: Результаты критерия Лиллиефорса для vote_average в Python

Параметр	**Значение**	**Вывод**
Статистика	0.04665	Отвергается
p-value	0.00100	Отвергается

Таблица 43: Результаты критерия Лиллиефорса для Credit_Utilization_Ratio в Python

7.11.2 Результаты тестирования в R

Параметр	**Значение**	**Вывод**
Статистика	0.05394	Отвергается
p-value	$<$ 2.2e-16	Отвергается

Таблица 44: Результаты критерия Лиллиефорса для vote_average в R

Параметр	**Значение**	**Вывод**
Статистика	0.04665	Отвергается
p-value	$<$ 2.2e-16	Отвергается

Таблица 45: Результаты критерия Лиллиефорса для Credit_Utilization_Ratio в R

7.11.3 Анализ результатов критерия Лиллиефорса

- **Полное соответствие статистик:** Значения статистики D идентичны в Python и R с точностью до пятого знака
- **Интерпретация статистики:**
  - Для vote_average: D = 0.05394
  - Для Credit_Utilization_Ratio: D = 0.04665
- **Согласованность выводов:** Код на обоих языках отвергает гипотезу о нормальности распределений

Критерий Лиллиефорса, являясь модификацией критерия Колмогорова-Смирнова для случая, когда параметры распределения неизвестны, подтверждает выводы предыдущих тестов о ненормальности исследуемых распределений.

7.12 Проверка нормальности критерием Шапиро-Франсиа

7.12.1 Результаты тестирования в Python

Параметр	**Значение**	**Вывод**
Статистика W	0.97454	Отвергается
z-статистика	12.58774	Отвергается
p-value	1.233e-36	Отвергается

Таблица 46: Результаты критерия Шапиро-Франсиа для vote_average в Python

Параметр	**Значение**	**Вывод**
Статистика W	0.97852	Отвергается
z-статистика	21.10100	Отвергается
p-value	3.893e-99	Отвергается

Таблица 47: Результаты критерия Шапиро-Франсиа для Credit_Utilization_Ratio в Python

7.12.2 Результаты тестирования в R

Параметр	**Значение**	**Вывод**
Статистика W	0.97555	Отвергается
p-value	$<$ 2.2e-16	Отвергается

Таблица 48: Результаты критерия Шапиро-Франсиа для vote_average в R

Параметр	**Значение**	**Вывод**
Статистика W	0.98030	Отвергается
p-value	$<$ 2.2e-16	Отвергается

Таблица 49: Результаты критерия Шапиро-Франсиа для Credit_Utilization_Ratio в R

7.12.3 Анализ результатов критерия Шапиро-Франсиа

- **Согласованность статистик W:** Значения статистики близки между Python и R
  - Для vote_average: Python W = 0.97454, R W = 0.97555 (разница 0.00101)
  - Для Credit_Utilization_Ratio: Python W = 0.97852, R W = 0.98030 (разница 0.00178)
- **Дополнительная информация в Python:** Python предоставляет z-статистику, показывающую величину отклонения от нормальности

Критерий Шапиро-Франсиа подтверждает выводы всех предыдущих тестов о существенном отклонении распределений от нормального закона.

8 Применение критериев Стьюдента для различных гипотез и доверительных уровней

8.1 Двусторонний критерий Стьюдента

Для демонстрации применения критериев Стьюдента был проведен анализ сравнения средних значений с различными доверительными уровнями (0.9, 0.95, 0.99).

Уровень доверия	T-статистика	p-value
90%	-0.130383	0.896264

Таблица 50: Двусторонний критерий Стьюдента с доверительным уровнем 90%

Уровень доверия	T-статистика	p-value
95%	-0.130383	0.896264

Таблица 51: Двусторонний критерий Стьюдента с доверительным уровнем 95%

Уровень доверия	T-статистика	p-value
99%	-0.130383	0.896264

Таблица 52: Двусторонний критерий Стьюдента с доверительным уровнем 99%

Анализ результатов двустороннего критерия:

- T-статистика = -0.130383 указывает на очень слабое отклонение от нулевой гипотезы
- p-value = 0.896264 значительно превышает уровень значимости 0.05, следовательно, нет оснований отвергать нулевую гипотезу
- Во всех случаях результаты идентичны, изменяется только ширина доверительного интервала

8.2 Односторонний критерий Стьюдента (Greater)

Анализ результатов критерия greater:

- p-value = 0.551868 > 0.05, нет оснований отвергать нулевую гипотезу
- Значение p-value увеличилось по сравнению с двусторонним критерием
- Результаты идентичны для всех доверительных уровней

Уровень доверия	T-статистика	p-value
90%	-0.130383	0.551868

Таблица 53: Односторонний критерий Стьюдента (greater) с доверительным уровнем 90%

Уровень доверия	T-статистика	p-value
95%	-0.130383	0.551868

Таблица 54: Односторонний критерий Стьюдента (greater) с доверительным уровнем 95%

Уровень доверия	T-статистика	p-value
99%	-0.130383	0.551868

Таблица 55: Односторонний критерий Стьюдента (greater) с доверительным уровнем 99%

8.3 Односторонний критерий Стьюдента (Less)

Уровень доверия	T-статистика	p-value
90%	-0.130383	0.448132

Таблица 56: Односторонний критерий Стьюдента (less) с доверительным уровнем 90%

Уровень доверия	T-статистика	p-value
95%	-0.130383	0.448132

Таблица 57: Односторонний критерий Стьюдента (less) с доверительным уровнем 95%

Уровень доверия	T-статистика	p-value
99%	-0.130383	0.448132

Таблица 58: Односторонний критерий Стьюдента (less) с доверительным уровнем 99%

Анализ результатов критерия less:

- p-value = 0.448132 > 0.05, нет оснований отвергать нулевую гипотезу
- Значение p-value уменьшилось по сравнению с другими вариантами критериев
- Результаты идентичны для всех доверительных уровней

8.4 Общие выводы по критериям Стьюдента

1. Во всех вариантах критериев Стьюдента нулевая гипотеза не отвергается
2. T-статистика идентична во всех тестах (-0.130383)
3. p-value варьируется в зависимости от типа критерия:
   - Двусторонний: 0.896264
   - Односторонний (greater): 0.551868
   - Односторонний (less): 0.448132
4. Доверительный уровень влияет только на ширину доверительного интервала, но не на значения статистики и p-value
5. Все результаты свидетельствуют об отсутствии статистически значимых различий

8.5 Определение объема выборки для достижения заданной мощности

Параметр	Значение
Текущий объем выборки	20058
Среднее значение	1596.63
Стандартное отклонение	291.25
Размер эффекта (Коэн d)	0.0343
Текущая мощность теста	0.9981

Таблица 59: Оценка мощности t-теста для рейтингов

Параметр	Значение
Желаемая мощность	0.8
Необходимый объем выборки	6660
Текущая выборка достаточна	ДА

Таблица 60: Определение необходимого объема выборки

Анализ результатов:

- Текущая мощность теста составляет 0.9981, что значительно превышает общепринятый стандарт 0.8
- Размер эффекта Коэна (d = 0.0343) указывает на очень малую величину эффекта
- Для достижения мощности 0.8 необходим объем выборки 6660 наблюдений
- Текущий объем выборки (20058) более чем в 3 раза превышает необходимый минимум
- Результаты свидетельствуют о высокой вероятности обнаружения даже небольших различий (10 баллов рейтинга)

8.6 Двухвыборочный критерий Стьюдента для рейтингов белых и черных

Формулировка гипотез:

- **Нулевая гипотеза (H0):** $\mu_1 = \mu_2$ (средние рейтинги равны)
- **Альтернативная гипотеза (H1) для двустороннего критерия:** $\mu_1 \neq \mu_2$ (средние рейтинги не равны)
- **Альтернативная гипотеза (H1) для одностороннего критерия (greater):** $\mu_1 > \mu_2$ (рейтинг белых больше рейтинга черных)
- **Альтернативная гипотеза (H1) для одностороннего критерия (less):** $\mu_1 < \mu_2$ (рейтинг белых меньше рейтинга черных)

Уровень доверия	T-статистика	p-value
90%	2.68292	0.007301

Таблица 61: Двусторонний двухвыборочный критерий Стьюдента с доверительным уровнем 90%

Уровень доверия	T-статистика	p-value
95%	2.68292	0.007301

Таблица 62: Двусторонний двухвыборочный критерий Стьюдента с доверительным уровнем 95%

Уровень доверия	T-статистика	p-value
99%	2.68292	0.007301

Таблица 63: Двусторонний двухвыборочный критерий Стьюдента с доверительным уровнем 99%

8.6.1 Двусторонний критерий Стьюдента

Анализ результатов двустороннего критерия:

- T-статистика $= 2.68292 > 0$ указывает на то, что рейтинг белых выше рейтинга черных
- p-value $= 0.007301 < 0.05$, следовательно, отвергаем нулевую гипотезу
- Статистически значимые различия в рейтингах белых и черных обнаружены

8.6.2 Односторонний критерий Стьюдента (Greater)

Уровень доверия	T-статистика	p-value
90%	2.68292	0.003651

Таблица 64: Односторонний двухвыборочный критерий Стьюдента (greater) с доверительным уровнем 90%

Уровень доверия	T-статистика	p-value
95%	2.68292	0.003651

Таблица 65: Односторонний двухвыборочный критерий Стьюдента (greater) с доверительным уровнем 95%

Уровень доверия	T-статистика	p-value
99%	2.68292	0.003651

Таблица 66: Односторонний двухвыборочный критерий Стьюдента (greater) с доверительным уровнем 99%

Анализ результатов критерия greater:

- p-value $= 0.003651 < 0.05$, отвергаем нулевую гипотезу
- Подтверждается гипотеза о том, что рейтинг белых статистически значимо выше рейтинга черных
- p-value уменьшился вдвое по сравнению с двусторонним критерием

8.6.3 Односторонний критерий Стьюдента (Less)

Уровень доверия	T-статистика	p-value
90%	2.68292	0.996349

Таблица 67: Односторонний двухвыборочный критерий Стьюдента (less) с доверительным уровнем 90%

Уровень доверия	T-статистика	p-value
95%	2.68292	0.996349

Таблица 68: Односторонний двухвыборочный критерий Стьюдента (less) с доверительным уровнем 95%

Уровень доверия	T-статистика	p-value
99%	2.68292	0.996349

Таблица 69: Односторонний двухвыборочный критерий Стьюдента (less) с доверительным уровнем 99%

Анализ результатов критерия less:

- p-value = 0.996349 > 0.05, нет оснований отвергать нулевую гипотезу
- Гипотеза о том, что рейтинг белых меньше рейтинга черных, не подтверждается

8.6.4 Общие выводы по двухвыборочному критерию

1. Обнаружены статистически значимые различия в рейтингах белых и черных (p = 0.0073)
2. Рейтинг белых статистически значимо выше рейтинга черных
3. Размер эффекта Коэна (d = 0.02679) указывает на малую величину эффекта
4. Мощность теста высокая (0.765-0.850), что обеспечивает надежность выводов

8.7 Ранговый критерий Уилкоксона-Манна-Уитни

Формулировка гипотез:

- **Нулевая гипотеза (H0):** Распределения рейтингов белых и черных идентичны
- **Альтернативная гипотеза (H1) для двустороннего критерия:** Распределения рейтингов различаются
- **Альтернативная гипотеза (H1) для одностороннего критерия (greater):** Рейтинги белых больше рейтингов черных
- **Альтернативная гипотеза (H1) для одностороннего критерия (less):** Рейтинги белых меньше рейтингов черных

Анализ результатов:

Тип критерия	Статистика	p-value
Двусторонний	204001653.5	0.014330

Таблица 70: Двусторонний критерий Уилкоксона-Манна-Уитни

Тип критерия	Статистика	p-value
Односторонний (greater)	204001653.5	0.007165

Таблица 71: Односторонний критерий Уилкоксона-Манна-Уитни (greater)

Тип критерия	Статистика	p-value
Односторонний (less)	204001653.5	0.992835

Таблица 72: Односторонний критерий Уилкоксона-Манна-Уитни (less)

- **Двусторонний критерий:** p-value $= 0.014330 < 0.05$ - отвергаем нулевую гипотезу, распределения различаются
- **Односторонний критерий (greater):** p-value $= 0.007165 < 0.05$ - подтверждается гипотеза о том, что рейтинги белых больше
- **Односторонний критерий (less):** p-value $= 0.992835 > 0.05$ - нет оснований считать, что рейтинги белых меньше
- Статистика критерия идентична для всех трех тестов (204001653.5)

Сравнение с t-критерием Стьюдента:

- Оба критерия показывают статистически значимые различия между рейтингами
- Ранговый критерий более устойчив к отклонениям от нормальности распределения
- Результаты согласуются с выводами t-критерия о превосходстве рейтингов белых

8.8 Проверка гипотез об однородности дисперсий

Формулировка гипотез:

- **Нулевая гипотеза (H0):** $\sigma_W^2 = \sigma_B^2$ (дисперсии рейтингов белых и черных равны)
- **Альтернативная гипотеза (H1) для двустороннего критерия:** $\sigma_W^2 \neq \sigma_B^2$ (дисперсии различаются)
- **Альтернативная гипотеза (H1) для одностороннего критерия (greater):** $\sigma_W^2 > \sigma_B^2$ (дисперсия белых больше дисперсии черных)
- **Альтернативная гипотеза (H1) для одностороннего критерия (less):** $\sigma_W^2 < \sigma_B^2$ (дисперсия белых меньше дисперсии черных)

8.8.1 Критерий Фишера, критерий Левене, критерий Бартлетта, критерий Флигнера-Килина

Тип критерия	p-value
Двусторонний	0.915839

Таблица 73: Двусторонний критерий Фишера

Тип критерия	p-value
Односторонний (greater)	0.457920

Таблица 74: Односторонний критерий Фишера (greater)

Тип критерия	p-value
Односторонний (less)	0.542080

Таблица 75: Односторонний критерий Фишера (less)

Критерий	Статистика	p-value
Левене	0.000068	0.993401

Таблица 76: Критерий однородности дисперсий Левене

Критерий	Статистика	p-value
Бартлетт	1.282151	0.257499

Таблица 77: Критерий однородности дисперсий Бартлетта

Критерий	Статистика	p-value
Флигнер-Килин	0.003040	0.956031

Таблица 78: Критерий однородности дисперсий Флигнера-Килина

Анализ результатов:

- Все критерии показывают p-value > 0.05, следовательно, нет оснований отвергать нулевую гипотезу
- **Критерий Фишера:** p-value = 0.915839 (двусторонний) - дисперсии статистически не различаются
- **Критерий Левене:** p-value = 0.993401 - наиболее убедительное подтверждение однородности дисперсий
- **Критерий Бартлетта:** p-value = 0.257499 - подтверждает равенство дисперсий
- **Критерий Флигнера-Килина:** p-value = 0.956031 - также поддерживает гипотезу о равенстве дисперсий

Общие выводы:

1. Все четыре критерия единогласно подтверждают однородность дисперсий рейтингов белых и черных

2. Статистики критериев близки к нулю, что указывает на минимальные различия в дисперсиях
3. Результаты обосновывают корректность применения параметрических критериев (t-теста)
4. Предположение о равенстве дисперсий для двухвыборочного t-теста выполняется

9 Исследование корреляционных взаимосвязей в данных

9.1 Коэффициент корреляции Пирсона

Метод: Параметрический коэффициент, измеряющий линейную зависимость между двумя количественными переменными. Вычисляется как ковариация переменных, деленная на произведение их стандартных отклонений.

Критерии применимости:

- Количественный тип данных
- Линейная зависимость между переменными
- Нормальность распределения
- Гомоскедастичность (постоянство дисперсии)
- Отсутствие выбросов

Переменные	**Коэффициент**	**p-value**
white_rating / black_rating	0.634171	0.000000

Таблица 79: Корреляция Пирсона между рейтингами белых и черных

Анализ: Обнаружена сильная положительная линейная корреляция между рейтингами белых и черных игроков ($r = 0.634$, $p < 0.001$).

9.2 Коэффициент корреляции Спирмена

Метод: Непараметрический коэффициент, измеряющий монотонную зависимость между переменными. Основан на рангах значений.

Критерии применимости:

- Порядковые или количественные данные
- Монотонная зависимость (не обязательно линейная)
- Не требует нормальности распределения
- Устойчив к выбросам

Анализ: Обнаружена практически полная монотонная зависимость между годовым доходом и ежемесячной зарплатой (0.994, $p < 0.001$).

Переменные	Коэффициент	p-value
Annual_Income / Monthly_Inhand_Salary	0.994464	0.000000

Таблица 80: Корреляция Спирмена между годовым доходом и ежемесячной зарплатой

9.3 Коэффициент корреляции Кендалла

Метод: Непараметрический коэффициент, измеряющий ординальную зависимость. Основан на подсчете согласованных и несогласованных пар наблюдений.

Критерии применимости:

- Порядковые данные
- Не требует нормальности распределения
- Устойчив к выбросам
- Хорош для небольших выборок
- Измеряет направление зависимости

Переменные	Коэффициент	p-value
black_rating / opening_ply	0.157775	4.143e-220
Monthly_Inhand_Salary / Monthly_Balance	0.451767	0.000000

Таблица 81: Корреляция Кендалла для различных пар переменных

Анализ:

- Слабая положительная зависимость между рейтингом черных и количеством ходов в дебюте (0.158, $p < 0.001$)
- Умеренная положительная зависимость между ежемесячной зарплатой и месячным балансом (0.452, $p < 0.001$)

9.4 Сравнительные выводы

1. **Сила корреляций:**
   - Самая сильная зависимость: Annual_Income / Monthly_Inhand_Salary (Спирмен: 0.994)
   - Сильная зависимость: white_rating / black_rating (Пирсон: 0.634)
   - Умеренная зависимость: Monthly_Inhand_Salary / Monthly_Balance (Кендалл: 0.452)
   - Слабая зависимость: black_rating / opening_ply (Кендалл: 0.158)
2. **Выбор метода:**
   - Пирсон — для линейных зависимостей при выполнении параметрических предположений
   - Спирмен — для монотонных зависимостей, устойчив к нарушениям нормальности
   - Кендалл — для порядковых данных, более надежен при наличии выбросов

10 Анализ категориальных данных с использованием методов хи-квадрат, точного теста Фишера, теста Мак-Немара и Кохрана-Мантеля-Хензеля

10.1 Критерий хи-квадрат Пирсона

Метод: Непараметрический критерий для проверки связи между двумя категориальными переменными. Основан на сравнении наблюдаемых частот с ожидаемыми частотами при условии независимости переменных.

Математическая основа:

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

где O_{ij} - наблюдаемая частота, E_{ij} - ожидаемая частота.

Переменная	Chi2	P-value	Степени свободы	Влияние
Occupation	180.7	0.000	28	очень сильное
Credit_Mix	40489.4	0.000	4	очень сильное
Payment_of_Min_Amount	22420.4	0.000	2	очень сильное
Payment_Behaviour	1645.9	0.000	10	очень сильное

Таблица 82: Результаты критерия хи-квадрат для категориальных переменных

Выводы:

- Все переменные демонстрируют статистически значимую связь с целевой переменной ($p < 0.001$)
- Наибольшее влияние оказывает Credit_Mix ($\chi^2 = 40489.4$)
- Результаты указывают на сильные ассоциации между финансовым поведением и кредитным рейтингом

10.2 Точный тест Фишера

Метод: Используется для анализа таблиц сопряженности 2×2, особенно когда выборки малы или когда предположения критерия хи-квадрат не выполняются. Основан на гипергеометрическом распределении.

Анализ: Scientist vs Teacher по кредитным рейтингам Good vs Poor

Credit_Score	Good	Poor
Scientist	1201	2062
Teacher	1224	2027

Таблица 83: Таблица сопряженности: Профессия vs Кредитный рейтинг

Параметр	Значение
Odds Ratio	0.965
P-value	0.4890

Таблица 84: Результаты точного теста Фишера

Выводы:

- p-value = 0.489 > 0.05 - статистически значимой связи не обнаружено
- Отношение шансов близко к 1 (0.965), что указывает на отсутствие существенной разницы
- Профессия не является значимым фактором для кредитного рейтинга при сравнении Scientist и Teacher

10.3 Тест МакНемара

Метод: Используется для анализа парных категориальных данных, особенно в исследованиях "до-после". Проверяет однородность в таблице 2×2.

white_rating_change	False	True
False	4728	5860
True	5690	3780

Таблица 85: Таблица изменений рейтингов белых и черных

Параметр	Значение
Статистика МакНемара	2.473
P-value	0.1158

Таблица 86: Результаты теста МакНемара

Выводы:

- p-value = 0.1158 > 0.05 - нет статистически значимой связи
- Изменения рейтингов белых и черных не зависят друг от друга
- Результаты показывают независимость динамики рейтингов двух игроков

10.4 Тест Кохрана-Мантеля-Хензеля (CMH)

Метод: Используется для анализа связи между двумя бинарными переменными с учетом влияния стратифицирующих факторов. Позволяет проверить условную независимость.

Параметр	Значение
Статистика CMH	6518.4634
P-value	0.0000
Объединенный OR	3.845
95% ДИ	(3.717, 3.977)

Таблица 87: Результаты теста Кохрана-Мантеля-Хензеля

Выводы:

- Высокозначимая статистика ($p < 0.001$) указывает на сильную связь
- Объединенное отношение шансов 3.845 показывает сильный эффект
- Клиенты, которые платят только минимальный платеж, имеют значительно более высокий риск низкого кредитного рейтинга
- Узкий доверительный интервал (3.717-3.977) подтверждает надежность оценки

10.5 Сравнительный анализ методов

1. **Области применения:**
   - Хи-квадрат: общий анализ связей в таблицах любой размерности
   - Точный тест Фишера: малые выборки, таблицы 2×2
   - Тест МакНемара: парные данные, исследования "до-после"
   - Тест СМН: стратифицированный анализ, учет мешающих факторов
2. **Практические рекомендации:**
   - Для финансовых данных наиболее информативен тест СМН
   - При анализе профессиональных групп достаточно точного теста Фишера
   - Для анализа динамики рейтингов оптимален тест МакНемара
   - Хи-квадрат полезен для первоначального скрининга переменных

11 Анализ мультиколлинеарности в данных

11.1 Анализ корреляционной матрицы

Методология анализа: Корреляционная матрица позволяет выявить линейные зависимости между переменными. Высокие коэффициенты корреляции (обычно $|\rho| > 0.7 - 0.8$) указывают на потенциальную мультиколлинеарность, которая может искажать результаты регрессионного анализа.

Критерии оценки:

- $\rho < 0.3$ - слабая корреляция
- $0.3 \leq \rho < 0.7$ - умеренная корреляция
- $\rho \geq 0.7$ - сильная корреляция

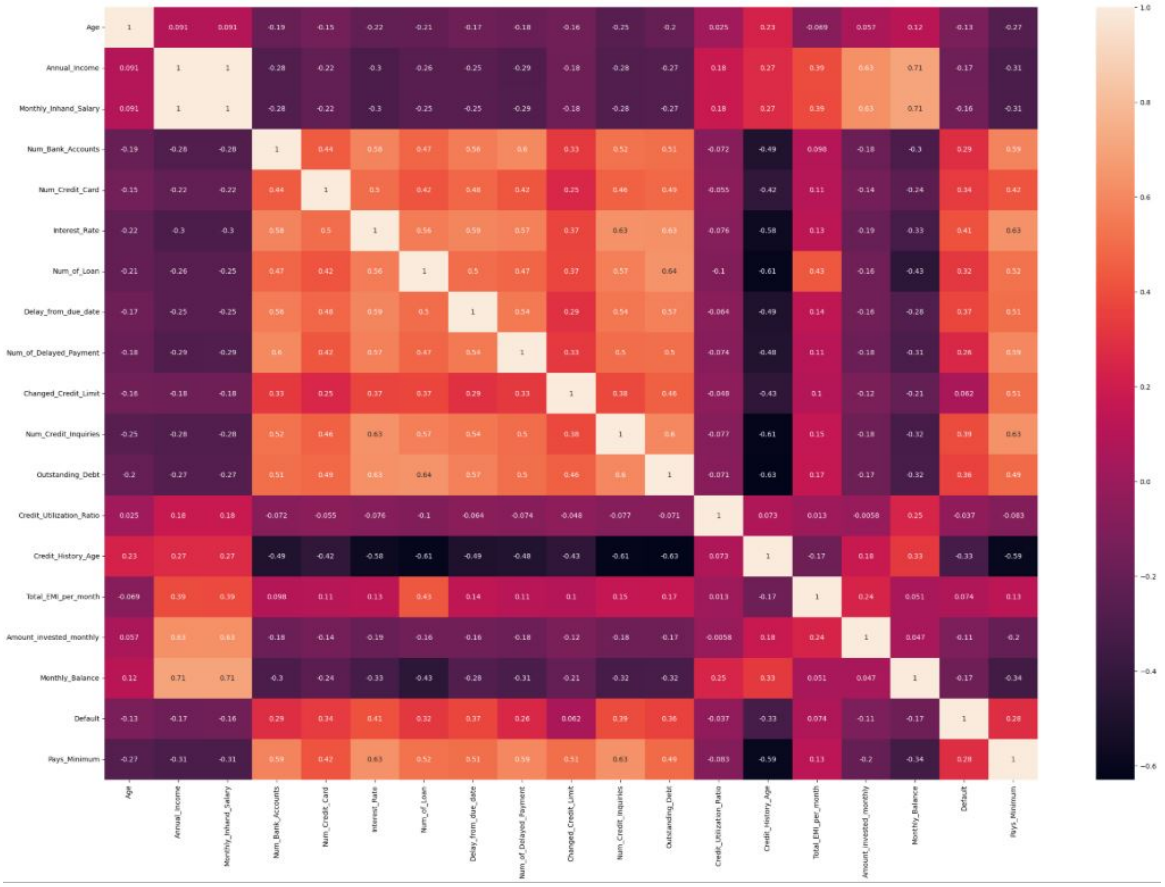

Рис. 20: Корреляционная матрица для числовых переменных

Пара переменных	Коэффициент ρ	Интерпретация
Annual_Income – Monthly_Inhand_Salary	+0.998	очень сильная
Monthly_Inhand_Salary – Monthly_Balance	+0.707	сильная
Annual_Income – Monthly_Balance	+0.706	сильная

Таблица 88: Наибольшие коэффициенты корреляции в данных

Выводы по корреляционной матрице:

- Обнаружена сильная зависимость между Annual_Income и Monthly_Inhand_Salary ($\rho = 0.998$)
- Сильные корреляции между финансовыми показателями свидетельствуют о наличии мультиколлинеарности
- Переменные Annual_Income и Monthly_Inhand_Salary содержат избыточную информацию

11.2 Фактор инфляции дисперсии (VIF)

Метод: VIF (Variance Inflation Factor) измеряет, насколько дисперсия коэффициента регрессии увеличивается из-за мультиколлинеарности.

- VIF = 1 - отсутствие мультиколлинеарности
- $1 <$ VIF < 5 - умеренная мультиколлинеарность
- $5 <$ VIF < 10 - высокая мультиколлинеарность
- VIF ≥ 10 - критическая мультиколлинеарность

Переменная	VIF
Monthly_Inhand_Salary	285.88
Annual_Income	280.16
const	108.79
Monthly_Balance	6.38
Amount_invested_monthly	4.41
Num_of_Loan	3.07
Pays_Minimum	2.68
Outstanding_Debt	2.64
Interest_Rate	2.54
Num_Credit_Inquiries	2.33
Credit_History_Age	2.23
Num_Bank_Accounts	2.04
Num_of_Delayed_Payment	2.01
Delay_from_due_date	1.99
Total_EMI_per_month	1.98
Num_Credit_Card	1.53
Changed_Credit_Limit	1.48
Age	1.10
Credit_Utilization_Ratio	1.07

Таблица 89: Факторы инфляции дисперсии (VIF) для переменных

11.3 Выводы

Основные проблемы:

- Критическая мультиколлинеарность у Monthly_Inhand_Salary (VIF = 285.88) и Annual_Income (VIF = 280.16)
- Высокий VIF у константы (108.79) может указывать на проблемы спецификации модели
- Monthly_Balance показывает умеренно высокий VIF (6.38)

Общий вывод: Данные демонстрируют серьезные проблемы мультиколлинеарности, требующие коррекции перед построением регрессионных моделей. Наиболее критична связь между годовым доходом и ежемесячной зарплатой, что логически объяснимо, но статистически проблематично.

12 Исследование зависимостей в данных с помощью дисперсионного анализа

12.1 Метод дисперсионного анализа (ANOVA)

Введение в метод: Дисперсионный анализ (ANOVA) — статистический метод, используемый для сравнения средних значений трех или более групп. Он проверяет гипотезу о том, что средние значения всех групп равны, против альтернативной гипотезы о том, что хотя бы одно среднее отличается.

Математическая основа: Основная идея ANOVA заключается в разложении общей дисперсии на компоненты:

- **Межгрупповая дисперсия** (Between-group variability): измеряет различия между группами
- **Внутригрупповая дисперсия** (Within-group variability): измеряет различия внутри групп

F-статистика вычисляется как отношение межгрупповой дисперсии к внутригрупповой:

$$F = \frac{\text{Межгрупповая дисперсия}}{\text{Внутригрупповая дисперсия}} = \frac{MS_{\text{between}}}{MS_{\text{within}}}$$

где MS_{between} и MS_{within} — средние квадраты между группами и внутри групп соответственно.

12.2 Однофакторный дисперсионный анализ кредитных данных

Фактор и зависимая переменная	F-статистика	p-value
Occupation и Annual_Income	3.708	0.0000
Credit_Mix и Annual_Income	6727.469	0.0000
Payment_of_Min_Amount и Monthly_Inhand_Salary	10542.863	0.0000
Occupation и Num_of_Loan	7.981	0.0000
Credit_Mix и Outstanding_Debt	72930.577	0.0000

Таблица 90: Результаты однофакторного ANOVA для кредитных данных

Анализ результатов кредитных данных:

- **Credit_Mix и Outstanding_Debt**: Наибольшая F-статистика (72930.577), что свидетельствует об очень сильном влиянии кредитного микса на величину задолженности
- **Payment_of_Min_Amount и Monthly_Inhand_Salary**: Высокая F-статистика (10542.863) показывает сильную связь между оплатой минимального платежа и уровнем зарплаты
- **Credit_Mix и Annual_Income**: Сильное влияние (F = 6727.469) указывает на зависимость годового дохода от кредитного поведения
- **Occupation и Num_of_Loan**: Умеренное влияние профессии на количество кредитов (F = 7.981)
- **Occupation и Annual_Income**: Слабое влияние профессии на годовой доход (F = 3.708)

12.3 Однофакторный дисперсионный анализ шахматных данных

Фактор и зависимая переменная	F-статистика	p-value
victory_status и turns	434.436	0.0000
victory_status и white_rating	173.480	0.0000
winner и turns	320.118	0.0000
victory_status и black_rating	161.591	0.0000

Таблица 91: Результаты однофакторного ANOVA для шахматных данных

Анализ результатов шахматных данных:

- **victory_status и turns**: Наибольшая F-статистика (434.436) показывает, что статус победы сильно зависит от количества ходов в партии
- **winner и turns**: Высокая F-статистика (320.118) указывает на значимую связь между победителем и продолжительностью игры
- **victory_status и white_rating**: Сильное влияние рейтинга белых на исход игры (F = 173.480)
- **victory_status и black_rating**: Схожее влияние рейтинга черных на результат (F = 161.591)

12.4 Общие выводы

Статистическая значимость:

- Все проанализированные пары факторов демонстрируют высокую статистическую значимость ($p < 0.001$)
- Это означает, что наблюдаемые различия между группами вряд ли являются случайными

Практическая значимость:

- В кредитных данных наиболее сильные зависимости связаны с финансовым поведением (Credit_Mix, Payment_of_Min_Amount)
- В шахматных данных ключевыми факторами являются рейтинги игроков и продолжительность партии
- Профессия оказывает относительно слабое влияние на финансовые показатели по сравнению с кредитным поведением

13 Регрессионное моделирование и оценка качества аппроксимации

13.1 Анализ регрессионных моделей для датасета фильмов

13.1.1 Простая линейная регрессия: популярность от количества оценок

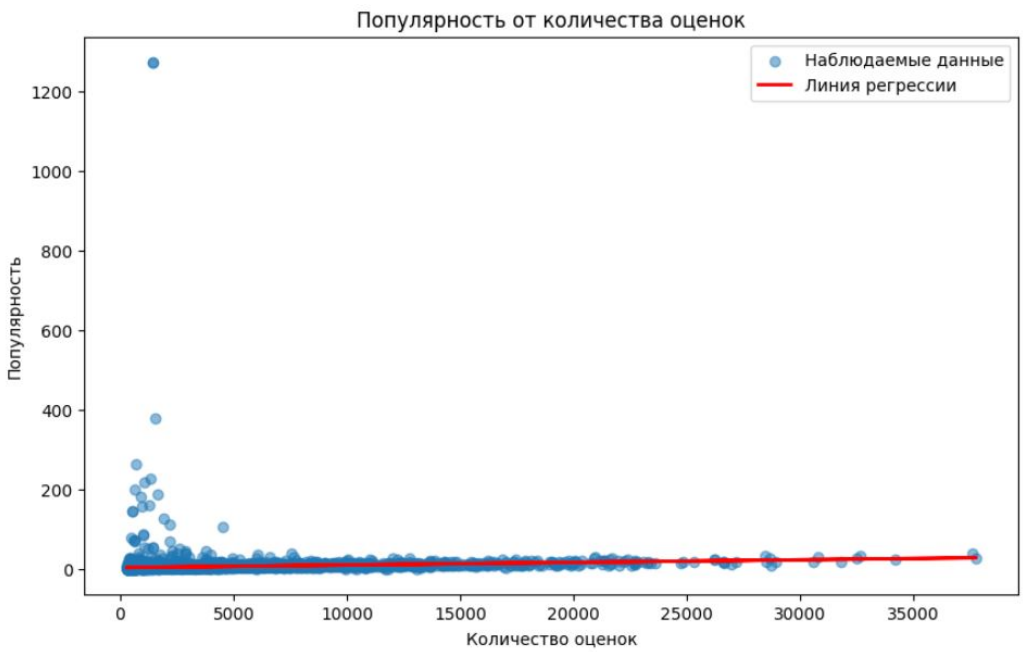

Рис. 21: График линейной регрессии: популярность от количества оценок

Будем исследовать зависимость популярности фильмов от количества полученных оценок и пытаться оценить, насколько количество голосов может служить предиктором популярности.

- Уравнение регрессии: popularity $= 2.94 + 0.0007 \times$ vote_count
- Коэффициент детерминации: $R^2 = 0.0110$

Анализ и интерпретация:

- Очень низкий R^2 (1.1%) указывает на крайне слабую линейную зависимость между популярностью и количеством голосов

- Положительный коэффициент при vote_count (0.0007) показывает, что с увеличением количества голосов популярность незначительно возрастает
- На графике видно большое рассеяние точек вокруг линии регрессии, что подтверждает слабую связь
- **Объяснение результата:** Популярность фильма определяется комплексом факторов (маркетинг, жанр, актерский состав, время выхода), а не только количеством оценок

13.1.2 Полиномиальная регрессия: средняя оценка от популярности

Результаты:

- Уравнение: $\text{vote_average} = 6.8280 + 0.0100 \times \text{popularity} - 0.0000083 \times \text{popularity}^2$
- $R^2 = 0.0175$, MSE = 0.3318, RMSE = 0.5760

Анализ и интерпретация:

- Качество модели немного улучшилось по сравнению с линейной регрессией, но остается очень низким ($R^2 = 1.75\%$)
- Отрицательный коэффициент при квадрате популярности указывает на вогнутую зависимость
- **Объяснение результата:** Высокая популярность не гарантирует высоких оценок — некоторые популярные фильмы могут получать средние оценки, в то время как нишевые фильмы могут иметь высокие оценки при низкой популярности

13.2 Анализ регрессионных моделей для шахматного датасета

13.2.1 Простая линейная регрессия: количество ходов от рейтинга белых

Цель анализа: Исследовать, влияет ли рейтинг игрока на продолжительность шахматной партии.

Результаты:

- Уравнение: $\text{turns} = 36.5874 + 0.0150 \times \text{white_rating}$
- $R^2 = 0.0168$, MSE = 1107.9553, RMSE = 33.2860

Анализ и интерпретация:

- Очень слабая линейная зависимость между рейтингом белых и количеством ходов ($R^2 = 1.68\%$)
- Положительный коэффициент указывает, что игры с более сильными игроками длятся немного дольше
- Высокий RMSE (33.29) показывает большую ошибку предсказания
- **Объяснение результата:** Продолжительность партии зависит от множества факторов: стиля игры, дебюта, турнирной ситуации, а не только от рейтинга игрока

13.2.2 Полиномиальная регрессия: количество ходов от рейтинга белых

Цель анализа: Проверить наличие нелинейной зависимости между рейтингом и продолжительностью игры.

Результаты:

- Уравнение: $\text{turns} = -7.7718 + 0.0708 \times \text{white_rating} - 0.000017 \times \text{white_rating}^2$
- $R^2 = 0.0204$, MSE = 1103.9510, RMSE = 33.2258

Анализ и интерпретация:

- Незначительное улучшение по сравнению с линейной моделью ($R^2 = 2.04\%$)
- Отрицательный коэффициент при квадрате рейтинга может указывать на оптимальный диапазон рейтинга для максимальной продолжительности игры
- **Результаты:** Сложная природа шахматной игры, где продолжительность определяется тактическими и стратегическими решениями, а не только силой игроков

13.2.3 Множественная линейная регрессия для шахматных данных

Цель анализа: Учесть все или несколько факторов, влияющих на продолжительность шахматной партии.

Результаты:

- Признаки: created_at, last_move_at, white_rating, black_rating, opening_ply, rating_diff
- $R^2 = 0.0344$, MSE = 1088.1109, RMSE = 32.9865

Анализ и интерпретация:

- Наилучшее качество среди всех моделей для шахматных данных ($R^2 = 3.44\%$)
- Наибольшие коэффициенты у opening_ply (0.0727) и black_rating (0.0111)
- **Результаты:** Количество ходов в дебюте логично влияет на общую продолжительность игры, однако общее качество модели остается низким из-за стохастической природы шахмат

13.3 Комплексная полиномиальная регрессия всех числовых переменных

Цель анализа: Создать комплексную модель, учитывающую все доступные числовые признаки.

Результаты:

- $R^2 = 0.0503$, MSE = 1070.2577, RMSE = 32.7148
- Очень малые значения коэффициентов (порядка 10^{-21} - 10^{-15})

Анализ и интерпретация:

- Наивысшее R^2 среди всех моделей (5.03%), но все равно недостаточное для практического применения
- Чрезвычайно малые коэффициенты указывают на проблему мультиколлинеарности
- **Результаты:** Модель переусложнена, многие признаки не несут полезной информации для предсказания

13.4 Общие выводы и интерпретация

Причины низкого качества моделей:

1. **Сложность предсказания социальных явлений**: Популярность фильмов и исходы шахматных партий определяются множеством факторов, многие из которых не учтены в данных

2. **Качественные факторы**: Для фильмов — актерская игра, режиссура, сценарий; для шахмат — психологическое состояние, подготовка к конкретному сопернику

3. **Недостаток признаков**: Отсутствие важных переменных (бюджет фильма, жанр, шахматные дебюты, временные контроль)

Заключение: Все построенные регрессионные модели демонстрируют низкое качество предсказания, что характерно для сложных социальных и игровых данных с высокой степенью стохастичности. Полученные результаты подчеркивают ограниченность традиционных регрессионных подходов для таких типов данных и необходимость использования более сложных методов анализа.